



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME

English  
Logo

Director: Prof Dr. rer. nat. Michael Herczeg

**Explainable Artificial Intelligence:  
Designing human-centric assessment system interfaces to  
increase explainability and trustworthiness of artificial  
intelligence in medical applications**

**Master's Thesis**

as part of the study program

**Media Informatics**

of the University of Lübeck

submitted by:

**Philipp Dominik Bzdok**

Issued and supervised by:

**Univ.-Prof. Dr. rer. nat. Thomas Franke, Dipl.-Psych.**

with support from:

**Tim Schrills, M.Sc.**

Lübeck, 1st December, 2021

## Vorbemerkung

(Version: 2021-05-12-IMIS LaTeX Version by Philipp Bzdok)

Anbei ein kommentiertes Template für Projekt- und Abschlussarbeiten in der Medieninformatik. Die grünen Kommentare in jedem Fall vor einer (Zwischen-) Abgabe entfernen (alle!).

Alle Angaben sind eigene Einschätzung (bzw. aus den zitierten Quellen, die aber auch wieder nach eigenen Überlegungen von mir ausgewählt wurden) und entsprechend ohne Gewähr. Nordstrom's Policy gilt auch hier: "Use your own best judgment at all times."

Es ist ihre Arbeit. Sie investieren 6 Monate Ihrer Lebenszeit in die Arbeit und Sie müssen Sie vor anderen verteidigen. Sehen Sie Hinweise von anderen als Ratschläge: Ernst nehmen, aber immer für sich selbst entscheiden, was passt, was nicht und was auf ein Problem hinweist, was man dann aber anders löst. Das letzte Wort (v.a. über formelle Aspekte) hat allerdings immer der jeweilige Betreuer.

Zunächst kommen ein paar allgemeine Vorbemerkungen, die für die ganze Arbeit relevant sind (Allgemeine Punkte der Arbeit). Danach die Gliederung einer normalen Arbeit mit Anmerkungen in den entsprechenden Kapiteln bzw. Abschnitten.

Viel Erfolg beim Schreiben.

Daniel Wessel

### **Rundumschlag was wissenschaftliches Arbeiten betrifft:**

[https://www.youtube.com/watch?v=\\_\\_ID7q7pXzyc](https://www.youtube.com/watch?v=__ID7q7pXzyc)

### **Allgemeine Punkte der Arbeit**

- **Änderbarkeit von Struktur und Inhalten:** Je nach konkretem Thema kann eine andere Struktur sinnvoll sein. Dies ist ins-besondere bei der Reihenfolge der Analyse-Abschnitte der Fall, kann aber auch ganze Kapitel betreffen. Das ist insbesondere bei Masterarbeiten der Fall, die sich je nach Ausrichtung (z. B. theoretische Arbeit) stark von der sonst üblichen Form unterscheiden. Diese Struktur so früh wie möglich mit dem Betreuer klären, ihm dann per eMail zuschicken und sich kurz bestätigen lassen (generell hat man viel zu tun und erinnert sich nicht unbedingt an alle Absprachen, deswegen einfach im Anschluss kurz eine Zusam-

menfassung des Gesprächs per eMail schicken).

- **Exposé (Bachelor-/Masterarbeit) bzw. Pflichtenheft (Bachelor-/Masterprojekt)** setzt die **inhaltliche Bewertungsgrundlage**: Darin haben Sie (Arbeit) oder Ihr Betreuer (Projekt) festgelegt, was zu erreichen ist. Entsprechend genau überlegen, was man verspricht bzw. zu was man sich verpflichtet.
- **Zielgruppe**: Schreiben Sie die Arbeit so, dass andere Personen verstehen, was Sie machen — auch wenn sie keine (Medien-)Informatik studiert haben. Sprich: Beginnen Sie breit um den Einstieg zu erleichtern und formulieren Sie es allgemein verständlich (z. B. das die öffentliche Verwaltung zunehmend digitalisiert wird) und fassen Sie am Ende eines Kapitels die Punkte allgemeinverständlich wieder zusammen. Dazwischen können Sie auf ein Detaillevel runtergehen und eine Komplexität nutzen, die ein Laie nicht mehr versteht. Da der Text in Absätzen aufgebaut ist, kann der Laie (oder nicht interessierte) diese Absätze überspringen. Der Laie sollte aber zumindest im Prinzip verstehen, was Sie gemacht haben.
- **Roter Faden**: Die Arbeit logisch aufeinander aufbauen: In der Einleitung legen Sie dar, was Sie erreichen wollen und zeigen dabei auch subtil, warum das wichtig / interessant / relevant ist (*"Why should I care?"*). Das geschieht über Belege und Argumente, wann immer Sie "wichtig", "interessant" oder "relevant" im Text verwenden sind Sie dabei gescheitert. **Alle** Kapitel nach der Einleitung zeigen **logisch aufeinander folgend**, wie der Zweck der Arbeit erreicht wird.
- **Zwischenstufen-Denken**: So schreiben, dass am Ende jedes Kapitels (Einleitung, Analyse, Konzeption, Realisierung, Dialogbeispiele, Evaluation) der Leser stoppen könnte und die Arbeit selbst fortführen könnte (z. B. nach der Einleitung sich für eine anderes Analyseverfahren entscheiden, oder auf Basis der Analyse eine andere Lösung konzipieren).
- **Eigenes Fazit am Ende jeden Kapitels — Was bedeuten die Ergebnisse für die Arbeit bzw. deren Ziel?** Z. B. am Ende der Analyse kurz zusammenfassen, was die wesentlichen Punkte für die weitere Entwicklung sind — mit Fokus auf das nächste Kapitel (hier: Konzeption). Am Ende der Konzeption kurz zusammenfassen, was die wesentlichen Punkte für die weitere Entwicklung (jetzt: Realisierung) sind, etc. pp. Ein gutes Fazit ist viel Arbeit und setzt ein gut geschriebenes Kapitel voraus.

- **Professionelle Zwischenabgaben:** Wenn Sie den Text an den Betreuer geben, gehen Sie vorher kritisch drüber. Wenn Textmarken falsch gesetzt sind, die Formatierung zusammengebrochen ist, etc. dann muss sich der Betreuer da erst mal durchwühlen um zum Inhalt zu kommen. Gute Formatierung macht keine schlechte Arbeit gut (die inhaltlichen Fehler fallen eher umso deutlicher auf), aber schlechte Formatierung macht eine gute Arbeit schlechter.
- **Professionell und offen Kommunizieren:** Weder sich selbst kreuzigen noch Fehler verbergen, sondern berichten, was gemacht wurde und mit Fehlern konstruktiv umgehen.

## Sprache: Stil

- **Kein Ich, keine Hero's Journey:** Es ist — im Prinzip — egal, wer die Arbeit durchgeführt hat (zumindest für die Qualität der Arbeit, nicht für die Bewertung Ihrer Leistung). Was überzeugen muss ist das Vorgehen, die Belege und Argumentation. Entsprechend stellen Sie das Vorgehen neutral dar ohne auf sich selbst zu verweisen (eher passiv verwenden). Ausnahmen sind u.a. in Danksagung, Widmung, Eidesstattliche Erklärung.
- **Meta vermeiden:** Sie müssen an vielen Stellen darauf hinweisen was kommt (z. B. zu Beginn eines jeden Kapitels). Reißen Sie den Leser aber dabei nicht aus dem Text. Mental ist der Leser dabei, ihre Arbeit zu beobachten, was Sie konkret getan haben. Wenn Sie ihm jetzt sagen "In diesem Kapitel ..." dann ziehen Sie ihn aus dem Text und bringen ihn dazu, über den Text nachzudenken statt über das, was gemacht wurde. Bleiben Sie bei dem, was Sie gemacht haben, z. B. "Nachfolgend werden ...".
- **Kapitel  $\neq$  Unterkapitel  $\neq$  Abschnitt:** 1 ist ein Kapitel, 1.1 ein Unterkapitel, 1.1.1 ein Abschnitt, 1.1.1.1 existiert nicht. Wenn Sie noch mehr Einteilungen brauchen, dann verwenden Sie Abschnitte mit Fettdruck zu Beginn (wie in diesem Abschnitt, dann aber ohne die Bulletpoints).
- **Kein Bulletpoint-Text:** Bulletpoints sind nur an wenigen Stellen hilfreich, z. B. bei Aufzählungen. Sätze nie mit Bulletpoints aufzählen. Entweder die Sätze auf Stichworte reduzieren oder eine Tabelle draus machen.
- **Auch digital gedrucktes ist tot und macht nichts mehr:** Sie berichten was

Sie gemacht haben — außerhalb des Berichtes. Entsprechend nie schreiben, dass z. B. in der Analyse der Sachverhalt analysiert wird. Der Bericht macht von sich aus nichts. Sie stellen dort die Ergebnisse der Analyse dar.

- **Umgangssprache vermeiden, Hochgestochene Sprache vermeiden:** Weder Umgangssprache (Sozialpädagogensprache; "tut", "Das Ganze ...", "etwas für ihre Gesundheit zu machen") noch Hochgestochen (à la Philosophendeutsch) schreiben. Wissenschaftliche Sprache ist nach Alley (1996):

- präzise: sagen was man meint (richtige Wort, richtiges Detaillevel)
- klar: vermeiden Sachen zu sagen/implizieren, die man nicht meint, d.h. Ambiguität und unnötige Komplexität (v.a. in der Wahl der Wörter) vermeiden
- ehrlich: direkt und offen kommunizieren
- prägnant: jedes Wort sollte zählen
- bekannt/vertraut: neue Fakten in bekannten Kontext verankern
- flüssig: von Satz zu Satz, Absatz zu Absatz, ohne dass der Leser stolpert

Alley, M. (1996). *The Craft of Scientific Writing* (Vol. 3). Springer

### **Sprache: Zeitformen**

- **In einem Bericht berichten Sie:** Entsprechend Vergangenheitsform verwenden. Sie berichten über eine abgeschlossene Arbeit, selbst wenn diese noch läuft als Sie es geschrieben haben, und selbst bei Zielen der Arbeit. Ausnahmen sind selten, z. B. bei den Ergebnissen ("Daten zeigen ..." — sie machen es ja noch) und Ausblick bzw. Vorschläge für die Zukunft.

### **Sprache: Absätze**

- **Eine Sinneinheit = 1 Absatz:** Absätze behandeln immer einen Punkt, eine Sinneinheit. Wenn eine halbe Seite lang kein Absatz verwendet wird, liegt meist ein Problem vor.
- **Absätze sind immer länger als ein Satz:** Keine Einsatz-Stückel-Absätze. Einzige Ausnahme: Sie wollen, dass der Leser die komplette Aufmerksamkeit auf

diesen zentralen Satz lenkt. Das kann man 1-2 Mal in einer Arbeit machen.

### Interne Verweise

- **Verweise statt Wiederholungen:** Üblicherweise braucht man einen Sachverhalt nur ein Mal zu beschreiben — dann verweist man an anderer Stelle auf den konkreten Abschnitt. Das ist auch der Grund für die Nummerierung — es erlaubt Ihnen, den Leser präzise zu den Punkt in der Arbeit zu schicken, an dem Sie auf den Sachverhalt eingehen. Nutzen Sie also "wie in der Kontextanalyse (2.4) beschrieben ...", dann weiß der Leser, wie lange er blättern muss.

### Zitationen

- **APA verwenden:** American Psychological Association (7. Ausgabe) Stil verwenden. Gibt genug Informationsseiten dazu im Netz und Literaturmanager können diesen Stil üblicherweise.
- **Richtige Zitationen:** Falsche "ich füg die richtigen Zitationen später ein" Abgaben verbrennen Ihnen den Betreuer. Arbeiten Sie von Anfang an mit einem Literaturverwaltungsprogramm, in dem die verwendeten Quellen richtig eingetragen sind (nächster Punkt).
- **Autorennamen müssen genannt werden, aber nicht hervorheben:** Die Wissenschaft sollte keinen Personenkult kennen — das können gerne Religionen oder Ideologien übernehmen. Wer was herausgefunden hat, ist egal. Die Qualität der Arbeit zählt. Entsprechend nicht "Die Autoren xyz haben herausgefunden das ABC vorliegt" sondern "Da ABC vorliegt (Autoren Jahr) ...".
- **Kein Paper-Denglish:** Ja, im englischen heißt es Paper. Im Text sind es aber Artikel oder Konferenzbeiträge oder Buchkapitel oder was auch immer. Üblicherweise muss man den Typ auch nicht erwähnen (im Normalfall wurde man eh Artikel/Konferenzbeiträge zitieren). Bitte nicht so was wie "Im Paper von xyz ...", das klingt nach Möchtegern-coole Manta mit Fuchsschwanz Sprechweise. Einfach berichten wie die Befundlage ist, über Autorennamen und Jahr (meist in Klammern) belegen wo es herkommt (sonst ein Plagiat) und die Belege und Argumente in der Arbeit sprechen lassen.
- **Wörtliche Zitate nur wenn es nicht anders geht:** In den meisten Fällen geben Sie Befunde oder Argumente mit Ihren eigenen wieder (mit Quellenangabe).

Wörtliche Zitate braucht man nur in sehr seltenen Fällen. Z. B. treffende Aussage von Evaluationsteilnehmern, oder eine Definition, die man 1:1 so sagen muss.

- **Fußnoten vermeiden:** Entweder es ist wichtig genug, genannt zu werden, oder es ist so unwichtig, dass es raus kann. Fußnoten reißen den Leser aus dem Text. Einzige Ausnahme: Bei der ersten Verwendung des generische Maskulinums.
- **Es gibt mehr Plagiate als nur Quellen nicht angeben:** Es gibt z. B. Übersetzungsplagiate, bei denen Sie einen Text(teil) einfach auf deutsch übersetzen ohne die Quelle anzugeben, oder dass man einfach die Argumentstruktur und Quellenangaben aus einem anderen Text übernimmt (ohne die Quelle anzugeben). Sie schmücken sich dann mit fremden Federn und Blender sind selten willkommen.
- **Literaturverwaltungsprogram nutzen:** Literaturverwaltungsprogramm (z. B. Zotero) hilft extrem bei der richtigen Zitierung, aber ACHTUNG: Wenn die Angabe in Zotero fehlt, ist auch die automatische Generierung des APA Stils falsch! GIGO gilt auch hier.

## Abbildungen und Tabellen

- Expliziter Verweis vom Text auf die Abbildung/Tabelle immer im Absatz vor der Abbildung/Tabelle (Leser stolpern über Abbildung/Tabelle, suchen dann nach oben nach mehr Informationen).
- Auf **Lesbarkeit** achten! Schriftgröße und Auflösung (bei Bildern) im Probedruck überprüfen!
- Für Schwarz/Weiß-Druck und für Farbfehlsichtige geeignet.
- Tabellen nach **APA Stil** (nur horizontale Linien und nur nach Header oder vor Footer).

## Druck

- Arbeit einseitig drucken!
- **PDF Druck und Suchfunktion:** Zuerst als PDF drucken, dann nach "Fehler! Verweisquelle konnte nicht gefunden werden." suchen. Word bricht schon mal gerne die Verlinkungen und das sieht man erst im Druck! Generell PDF Dokument kritisch durchgehen und PDF auch zum Drucken im Copyshop verwenden!

- Nach dem Druck und vor dem Binden alle Seiten selbst sowie von einer anderen Person durchgehen (lassen).



# Acknowledgement

Kurzer Dank an Personen, die Sie bei der Arbeit unterstützt haben. Z. B. inoffizielle Betreuer, Teilnehmer an den Evaluationen (nie namentlich nennen), Medientechnik, Sekretärin, etc. pp. — nur wenn Sie den Personen wirklich dankbar sind. (Ist nett aber für die Bewertung irrelevant.) Falls nicht verwendet diese Seite einfach entfernen.

Text ...

# Kurzfassung

Abstract schon für Zwischenabgabe schreiben. Später kommen dann noch Sätze dazu, aber Grundgerüst steht.

Kein "Teaser" sondern eine kurze Zusammenfassung (das, was man braucht, um sich schnell einen Überblick zu verschaffen, ob es sich lohnt, die Arbeit zu lesen).

Inhalt umfasst die zentralen Punkte aller Kapitel, von Ziel/Fragestellung bis Ausblick.

Nie länger als diese eine Seite (inkl. Schlüsselwörter).

Text ...

## Schlüsselwörter

Verwendete Literatur gibt Hinweise auf passende Stichwörter. Das sind die Suchbegriffe, die man bei einer Literatursuche verwenden würde.

Text ...

# Abstract

Englische Version der Kurzfassung. Nicht einfach Google Translate oder DeepL verwenden. Trifft die Nuancen nicht und klingt z. T. nach Yoda.

Text ...

## Keywords

Text ...

# Contents

<b>1</b>	<b>Introduction</b>	<b>1</b>
1.1	Goals . . . . .	3
1.2	State of the Art . . . . .	4
1.3	Approach . . . . .	8
<b>2</b>	<b>Analysis</b>	<b>10</b>
2.1	Data Sources . . . . .	10
2.1.1	Scientific Literature . . . . .	10
2.1.2	Interviews . . . . .	11
2.1.3	Existing Applications . . . . .	13
2.2	Context Analysis . . . . .	15
2.3	Problem and Task Analysis . . . . .	16
2.4	User Analysis . . . . .	18
2.4.1	Medical professionals . . . . .	18
2.4.2	Data scientists and AI researchers . . . . .	20
2.5	Conclusion on the Analysis . . . . .	21
<b>3</b>	<b>Conception</b>	<b>22</b>
3.1	Conceptual Approach . . . . .	22
3.2	Use Cases . . . . .	23
3.2.1	Understanding through Interaction . . . . .	23
3.2.2	Comparison of Models . . . . .	23
3.3	Functionalities . . . . .	24
3.3.1	Explanation Techniques . . . . .	26
3.4	System Architecture . . . . .	29
3.5	Interaction Design . . . . .	30
3.5.1	Interaction Dialogues . . . . .	31
3.5.2	Interaction Flowcharts . . . . .	32
3.6	Interface Design . . . . .	34

3.7	Conclusion on the Conception . . . . .	35
<b>4</b>	<b>Implementation</b>	<b>37</b>
4.1	System Architecture Implementation . . . . .	38
4.2	Interface Implementation . . . . .	38
4.3	Conclusion on the Implementation . . . . .	38
<b>5</b>	<b>Dialogue Samples</b>	<b>40</b>
<b>6</b>	<b>Summative Evaluation</b>	<b>41</b>
6.1	Goal . . . . .	41
6.2	Methods . . . . .	41
6.2.1	Design . . . . .	42
6.2.2	Participants . . . . .	42
6.2.3	Setting and Instruments . . . . .	42
6.2.4	Procedure . . . . .	43
6.3	Results . . . . .	44
6.4	Discussion . . . . .	45
6.5	Conclusion on the Evaluation . . . . .	45
<b>7</b>	<b>Summary and Outlook</b>	<b>46</b>
7.1	Summary . . . . .	46
7.2	Outstanding Issues . . . . .	46
7.3	Outlook . . . . .	47
7.4	Final Conclusion . . . . .	47
	<b>List of Figures</b>	<b>48</b>
	<b>List of Tables</b>	<b>49</b>
	<b>Sources</b>	<b>50</b>
	References . . . . .	50
	Websites . . . . .	53
	Software . . . . .	53
	<b>Abbreviations</b>	<b>54</b>
	<b>Glossary</b>	<b>55</b>

<b>Appendices</b>	<b>56</b>
Appendix A: Inhalt der DVD . . . . .	56
Appendix B: Interview Guideline . . . . .	57
Appendix C: Interaction Flowcharts . . . . .	71
<b>Assertion under Oath</b>	<b>78</b>

# 1 Introduction

The use of modern Artificial Intelligence (**AI**) techniques is pervasive and can be found in many fields of application, such as digital image processing, search engines and speech recognition (European Commission, 2020). Other application fields, such as medical diagnosis systems, cannot benefit as easily from AI-based technology compared to recreational domains. This impediment stems oftentimes from the AI being a "black box". In consequence humans struggle to understand such AI-systems and their output, leading to trust and compliance issues (Adadi & Berrada, 2018). These issues are further enhanced in the medical context where decisions, possibly based on AI, can have severe consequences for users, especially patients.

An example for medical human-AI-interaction is the image-based recognition of Deep Vein Thrombosis (**DVT**) with real time AI support for medical professionals by *ThinkSono*. The system leverages AI to guide the user through the current gold-standard diagnosis, a compression ultrasound examination, so that it enables any healthcare professional to detect DVT (ThinkSono, 2021). Closely related in this context is the interdisciplinary research project *CoCoAI*, which aims to explore psychological, ethical and technological implications of human-centered, AI-based applications in the DVT diagnosis and beyond (CoCoAI, 2021).

When AI-based systems are used in high risk application contexts, such as medical diagnosis, the aspects of explainability, interpretability and trustworthiness become a primary concern for adoption and use of said system. Ribeiro et al. (2016) already explored the importance of explainability and trust in AI-based systems and postulated that AI systems will not be used if the users have no trust in the model or the results. Even though many machine learning algorithms score high on standard performance metrics, such as precision, recall or Area Under the Receiver Operating Characteristics (**AUROC**), user-facing performance may be way worse (Gordon et al., 2021). Understanding the AI's underlying machine learning (**ML**) model and its predictions is an important step for assessing trust and facilitating effective interaction (Ribeiro et al.,

2016). Recent technological advances are realized by *Clearbox AI*, with the focus on trustworthy AI by implementing an AI model assessment (Clearbox AI, 2021b; European Commission, 2021). The model assessment can help model owners to identify robustness issues, potential undesired behaviour, and explain errors and uncertainties regarding the model predictions (Clearbox AI, 2021a).

Trust in AI systems is primarily induced by the users' understanding and the general interpretability of the machine learning model and their predictions (Ras et al., 2018; Ribeiro et al., 2016). The wide array of different possible user groups and the complex constructs of understandability and trust demands for a human-centric approach in designing AI assessment systems. Because of the inherent complexity of non-linear machine learning models, especially Deep Neural Networks (**DNNs**) for image processing, suitable visualization and communication techniques are non-trivial. Additionally to the complex models for image classification, the input data is also more complex as it is unstructured. Non-linear neural networks and unstructured data provide additional challenges for Explainable Artificial Intelligence (**XAI**), as described in Keane and Kenny (2019). XAI is a research field that studies how AI decisions and data driving those decisions can be explained to people in order to provide transparency, enable assessment of accountability, demonstrate fairness, or facilitate understanding (Arrieta et al., 2019). XAI plays an important role in the acceptance and finally in the usage of AI-based technology. This is further underlined in the medical context where public authorities set strict regulations on the usage of technological systems and ethic concerns have to be thoughtfully addressed.

In the context of a image-based medical diagnosis system, it is important that the responsible stakeholders, such as medical practitioners, specialized doctors and clinic managements, are enabled to make informed decisions on the usage of AI-based technology, even though their expertise in machine learning and data science is expected to be low. The stakeholders' trust in this system is a primary factor for the widespread use of said technology for real life applications. Therefore, increasing the understanding of the AI model and finding an optimal trust level in the predictions by designing human-centric explanation techniques within the AI model assessment system is a main goal of this work. Additionally it is conceivable that authorities will instantiate auditors for AI-based systems in medical contexts. Having a comprehensible and scientifically proven assessment system could be a big step in the approval and adoption of said system.



## 1.1 Goals

The users understanding of the AI model and trust in the model are highly essential as pointed out by Knapič et al. (2021). This holds especially true for medical applications where re-traceable results have to be provided and people acting on these results bear great responsibility. To facilitate understanding and trust the machine learning model has to be interpretable and explainable. In the context of Convolutional Neural Networks (CNNs) interpretability of models can pose a significant concern because of their inherent complexity. Explanations of AI-models can provide insights on the machine's decision process and therefore generate user understanding. This can lead to the model being more interpretable by humans.

Assessing the suitability and performance of a CNN for a specific task by applying standard performance evaluation metrics is problematic, since these can be oblivious to distinguishing the diverse problem solving behaviors of a neural network (Lapuschkin et al., 2019). Lapuschkin et al. (2016), Ribeiro et al. (2018), Samek et al. (2021) give an overview on the technical foundations of XAI and a presentation of practical methods, which will be used in conjunction with human-centric design to explore and evaluate suitable and efficient methods to explain a model's classification.

The goal of this thesis is to design, develop and evaluate interactive AI-assessment-system artifacts for medical professionals and machine learning specialists in a human-centric fashion to facilitate understandability and trustworthiness of AI-models. Developing such a system, with human concerns in focus, leads to following research questions:

- Q1: How is the stakeholders' (medical professionals, clinic managements or data scientists) subjective information processing awareness linked to trust for a specific model and its predictions in the medical domain?
- Q2: How can different explanation techniques, ranging from perturbation based approaches to more model intrusive alternatives, increase trust in image classifier models and predictions?
- Q3: What are the most efficient methods to explain and possibly optimize trust levels in image classification models?
- Q4: To what extend can structured metadata increase the stakeholder's understanding of a model's operational range and performance?

## 1.2 State of the Art

An AI-assessment-system is currently offered by Clearbox AI. The *AI Control Room* cloud platform enables users to assess, improve and validate ML models and data in accordance with the principles of Trustworthy AI (Clearbox AI, 2021b; European Commission, 2021). Clearbox AI (2021b) describes its AI-assessment-system as a "Deep Pre-production Analysis" tool:

"AI Control Room automatically generates a model assessment to help model owners to identify robustness issues, potential undesired behaviour, and explain errors and uncertainties regarding the model predictions."

Concretely the product enables users to perform following tasks for AI models working on tabular data:

**Model behaviour validation:** Validation metrics and plausible causes of error are clearly presented, potential limitations and irreducible uncertainty are identified and local explanations of the model behaviour are generated selecting representative points in the dataset.

**Synthetic data generation:** A generative model can be used to create synthetic data points that preserve the statistical properties of the original dataset. These points can augment the original training set to improve generalization, to increase model robustness, and to oversample specific labels when in the presence of unbalanced data.

**Data-centric analysis:** Generative models perform a probabilistic analysis of the underlying data allowing for robust outliers detection and uncertainty analysis. This information can help you to evaluate data quality.

**Centralised tracking system:** AI Control Room acts as a centralised tracking system to store lineage, versioning, and metadata of your datasets and models. Assessments generated are securely persisted along with models and datasets.

Besides general information and standard metrics (see Figure 1.1) the assessment system offers varied insights into different aspects of the machine learning model: Figure 1.2 shows graphs of training and validation precision, recall and calibration, while Figure 1.3 shows the models strong points and limitations by analyzing the feature distribution in

the data. Furthermore, the second half of the model assessment focuses more on the interpretability aspect of machine learning: Figure 1.4 shows a confusion matrix of possible classification results, which is then extended by example data points, chosen by the assessment system (see Figure 1.5). These examples can then be further explored to generate understanding of the models inner workings by applying an attribution based explanation technique combined with a decision rule explanation.



Figure 1.1: AI Control Room - Model Assessment Overview with Standard Metrics



Figure 1.2: AI Control Room - Precision-Recall and Calibration Graphs



Figure 1.3: AI Control Room - Model String Points and Limitations



Figure 1.4: AI Control Room - Interpretability Assessment

HOME	GRADE	PURPOSE	INQUIRIES	DELINQUENCY	LOAN_AMOUNT	BANKRUPTCIES	FICO_AVERAGE	VERIFICATION
Mortgage	2	debt_consolidation	4	0	10000	0	732	Not Verified
Mortgage	4	other	5	5	8000	0	667	Source Verified
Rent	6	other	5	0	18000	0	677	Verified
Mortgage	5	credit_card	8	0	12500	0	677	Verified
Rent	7	debt_consolidation	3	0	5875	0	642	Not Verified
Mortgage	3	credit_card	5	0	19000	0	722	Verified

Figure 1.5: AI Control Room - Example Data

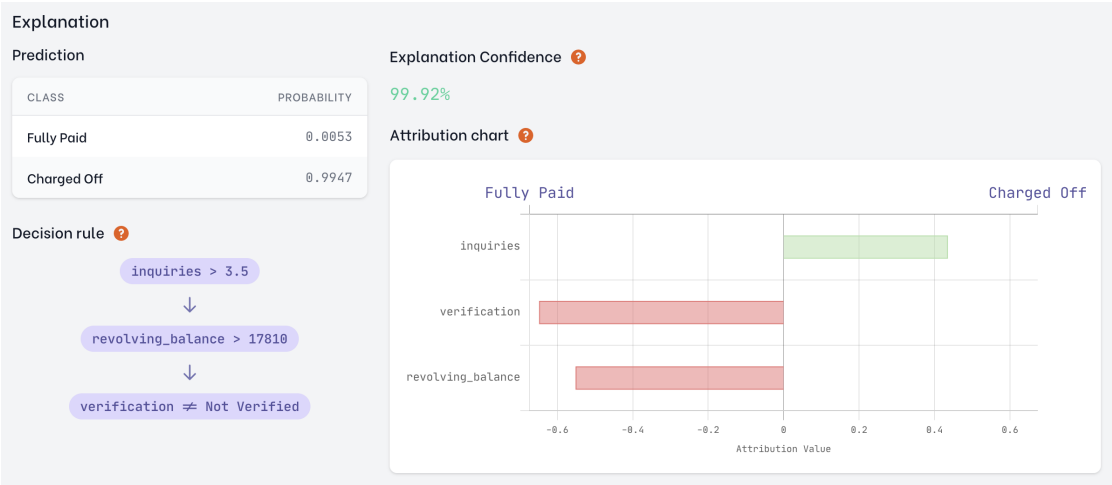


Figure 1.6: AI Control Room - Prediction Explanation for Examples Data

## 1.3 Approach

As already described in the introduction of chapter 1, many machine learning algorithms score high on standard performance metrics, but user-facing performance may be way worse (Gordon et al., 2021). This issue is caused by real world applications being very dependent on the actual human-AI-interaction. Following this reasoning, it lends itself to utilize a human-centered design process for creating AI-assessment systems. Figure 1.7 shows a standardized process of human-centered design, which was applied in this thesis to conceptualize, implement and evaluate assessment system artifacts. The key take-away is the inclusion of human aspects in all stages of the process. Research on evaluation of AI explanations revealed that there is a big gap between the perceived and actual usefulness of explanations, as described by Ras et al. (2021). This further underlines the need for a human-centered approach in designing AI-assessment-systems.

The thesis' structure will reflect the human-centered approach, which is visualized in Figure 1.7: As already alluded in chapter 1, chapter 2 is about understanding and setting the context of use by conducting literature research and user interviews. Based on the established requirements chapter 3 will describe the conception of functionalities and interaction design. The development of solutions will be described in chapter 4, while chapter 6 is about the evaluation of the solutions. This general process is embedded in a iterative loop, where intermediate results are evaluated against the requirements and subject to change.




Figure 1.7: Human-centered Design Process (*DIN EN ISO 9241-210*, 2011)

## 2 Analysis

Following the human-centered design process, it is important to incorporate the potential users from the beginning. This is also reflected in the analysis, where the context and setting of use has to be understood and set. Besides the human factors, there are also more general and theoretical aspects to be analysed, such as the context of AI in the medical application domain for specific tasks, such as classifying disease patterns with medical imaging.

In the following the context, task, problem and users will be described and analysed as a foundation for the human-centered design process and the following conception of AI assessment system artifacts.

### 2.1 Data Sources

Three main data sources were used for the analysis, ranging from general scientific literature about XAI to specially elaborated user interviews and cooperation with developers of an existing application.

#### 2.1.1 Scientific Literature

Literature is the foundation of the analysis. As described by Mueller et al. (2019), the amount of scientific publications on the topic of explanation in intelligent systems has surged in the last 5 years, revealing many important and relevant information on this subject area through openly accessible papers. In the beginning of the thesis (July 2021) a general search on *Google Scholar* was conducted to gain an overview on available publications. A non-exhaustive list of search terms at the time was:

- XAI



- XAI in Medical Applications
- Explainable Artificial Intelligence
- Explainable Artificial Intelligence in Medical Applications
- Explainable Machine Learning
- Interpretable Machine Learning
- Explaining Black-Box Machine Learning Models
- Explaining DNNs

This general research yielded already good results, as there were many relatively new and popular publications on the topic of XAI, such as Adadi and Berrada (2018), Hoffman et al. (2019), Mueller et al. (2019), Ras et al. (2018).

The results of the internet research were then further reinforced by academic partners from the University of Lübeck, with whom related research was conducted in the context of the *CoCoAI* project. Leveraging the available resources and support from research partners boosted the yield on relevant scientific literature tenfold. Over the course of multiple months the list of literature grew and is still being maintained in a shared *Zotero* library (Corporation for Digital Scholarship, 2021). The most important scientific papers for this analysis were: Adadi and Berrada (2018), Arrieta et al. (2019), Chiou and Lee (2021), Hoffman et al. (2019), Knapič et al. (2021), Ras et al. (2018), Ribeiro et al. (2016), Samek et al. (2021).

### 2.1.2 Interviews

Complementing the general research on XAI, specially elaborated user interviews were conducted. These interviews specifically target medical professionals and data scientists. Interviews with the actual user group of a potential solution is key to understanding and setting the context and requirements of use. The participants for the interviews were chosen with following requirements in mind:

**Medical Professionals:** Has interest and/or knowledge in AI-systems; has worked with or researched AI-systems in the medical domain; can judge the benefits and risks

of the use of AI in medical applications.

**Data Scientists / AI Researchers:** Is familiar with the XAI topic; has interest in explainability and trustworthiness of machine learning models; has worked with AI in the medical context.

Participants for the interviews were gathered via academic partners, internet research and word of mouth. In total 16 suitable people from 6 different institutions (among them UKSH, TU München and Mevis Fraunhofer Bremen) were contacted about potential interviews. Ten leads were medical professionals while six leads were data scientists or AI researchers. From the total of 16 potential interview partners only four interviews have been conducted. This low yield is due to the time constraint of the individuals, who are mainly full time medical practitioners or researchers. The participants are described in further detail in Table 2.1.

ID	Age	Gender	Occupation	Education Level	AAII Score
1	28	male	Assistant Physician in Neuroradiology	State Examination	4.89
2	24	female	Research Associate (ML)	Masters Degree	5.12
3	48	male	Surgeon	Dr. med.	5.45
4	27	female	Assistant Physician in Neuroradiology	State Examination	4.67

Table 2.1: Interview Participants

The Interviews were conducted in German and executed as 1 to 1 online interviews. For reference the interviews were recorded if consent was present. Additionally the interviews were supported by a research colleague, who kept protocol. After the interviews the recordings were transcribed for further analysis and the participants were asked to answer the *Affinity for AI Interaction (AAII)* questionnaire, which is a modified version of the *Affinity for Technology Interaction (ATI)* questionnaire (Franke et al., 2019). ATI aims to determine the tendency to actively engage in intensive technology interaction, as a key personal resource for coping with technology. Analogously the AAI questionnaire aims to determine the tendency to actively engage in AI interaction.

In terms of content, the interviews for medical professionals and data scientists were slightly different as seen in Table 2.2. The reason for this is the heterogeneous expertise on the subject area of machine learning models and potential user requirements. The

whole interview guideline can be found in section 7.4.

Medical Professionals	Data Scientists / AI researchers
Actual Usage of AI	Actual Usage of AI
Perspective on AI Usage	Comparison of AI Models
Trust in AI	Perspective on AI Usage
Potential Problems with AI Usage	Trust in AI
Own Explanation Techniques	Potential Problems with AI Usage
Familiarity with XAI	Own Explanation Techniques
Assessment on Local Explanations	Familiarity with XAI
Information Processing	Need for Local Explanations
Reliability vs. Trust vs. Understanding	Need for Global Explanations
	Information Processing
	Trust-Behavior Connection
	Reliability vs. Trust vs. Understanding

Table 2.2: Interview Topics

After gathering the interview data via protocols and transcripts a thematic analysis according to Braun and Clarke (2006) was applied to identify common topics and codes. The thematic analysis is a widely used qualitative analysis method mainly found in the field of psychology and can be used as a primary tool to access data from interviews. Applying this method resulted in a thematic map showcasing common overlapping topics found in the interviews, which can be seen in Figure 2.1. The thematic map serves as the baseline for further context and requirement analysis.

### 2.1.3 Existing Applications

A scientific cooperation with Clearbox AI allowed us to access a additional source of information, valuable for the analysis and conception. As already described in section 1.2 Clearbox developed an AI model assessment solution among other things. During the period of cooperation regular meetings were held with the CTO and other employees. These meetings were used for knowledge exchange on the subject of XAI literature, previous experiences, feedback and conceptional workshops.

The enormous previous experience of Clearbox is a great resource of information for the thesis. Many aspects of analysis and conception were supported by the regular, bi-weekly meetings. In particular, resources such as Facebook (2021), Google (2021), Lapuschkin



Figure 2.1: Thematic Mind Map

et al. (2019), Streamlit Inc. (2021) were supplied by Clearbox. Furthermore the (beta) access to the Clearbox AI *Control Room* cloud platform and the communication of user feedback was invaluable to gather information on the analysis and conception of an assessment system for image-based AI models.

## 2.2 Context Analysis

Black-box DNNs have become pervasive in today's society and represent a proven and indispensable machine learning tool. While these machine learning models can easily be used in recreational non-risky contexts, this does not hold true for the medical domain where decisions based on the results of a machine learning model can bear great risks for users and patients. This issue stems from the lack of interpretability and trustworthiness of DNNs (Adadi & Berrada, 2018). DNNs architectures are inherently hard to understand and therefore interpretability of and trust in the results of such neural networks are a challenge.

Creating a solution to explain AI models a priori to the use can help setting the right expectations towards the AI model. Consequently the users of such an explanatory system gain the ability to build a fair mental model before using the AI, which in turn can support the formation of appropriate levels of trust (Hoffman et al., 2019). This is beneficial to the user and facilitates efficient usage of the model in production (Google, 2021; Hoffman et al., 2019).

Explaining the model a priori also enables the solution to build computationally complex explanations, which can depend on datasets of thousands of images. Supplying the user with explanations potentially based on the whole dataset can also be beneficial: Statistical analysis and clustering of the data and metadata can support the understanding of model limitations and edge cases, while exemplary local explanations can be statistically distributed to gain a better overview of global behavior of the model. Combining different types of a priori explanations improve the coverage of the key attributes of explanations - understandability, feeling of satisfaction, sufficiency of detail, completeness, usefulness, accuracy, and trustworthiness - which were described by Hoffman et al. (2019).

The aspects mentioned above are also reflected in the interview data. The following list showcases translated quotes from interview partners regarding the need for (a priori)

explanations for AI models aimed at the medical domain:

"I think you have to be critical and look at the results carefully - is the result at all plausible?"

"What is the information that is interesting for the system or that is decisive for the decisions? What information is rather irrelevant?"

"If the explanations for the model are based on any data that are meaningless from my clinical experience, such as a stroke being pinned down by bone shapes. That would shake my confidence in the machine, even though it might give reliable results."

"If, for example, there is an outlier data point in a specific case and you are not quite sure why it is like this or how you should interpret it, then something like this [local explanation] is great, so that you can understand why the result is like this or like this."

"I've always been interested in exactly how this works, how much training data it's based on, what's behind it, why the system decides the way it does."

"[...] and you might also learn what the machine pays attention to, which I personally could also pay attention to when I look at the picture. That would certainly strengthen my confidence in the application."

## 2.3 Problem and Task Analysis

The following problem scenario summarizes the starting point of the problem and task analysis: The general medical practitioner Dr. med. Mustermann wants to offer thrombosis diagnosis in his office. He is not specialized in vein examination and thus has just basic knowledge and also no necessary equipment. In the past this has led to him referring patients with venous disorders to a specialized clinic. Through a colleague he was made aware of "*AutoDVT*", a AI-based software developed by ThinkSono, which can help him offer DVT diagnosis in his office. The AutoDVT system works with image-based machine learning and can support medical professionals in real time with identifying DVT. Since Dr. med. Mustermann has very little knowledge of AI and machine learn-

ing he is very skeptical towards this innovative but foreign software system. Although he sees the immediate benefits of using a system which supports him with the examination of DVT, his trust in the system's predictions is very low and he fears relying on the AI's assessment. AI-based technology is a black box for him, which he does not fully understand. The predictions of the systems are opaque to him and thus lead to rejection of the system.

DNNs for image classification are able to detect various disease patterns with medical imaging and can be used by medical professionals to support diagnosis and possibly increase efficiency and effectivity if trusted and used correctly (Adadi & Berrada, 2018; Knapič et al., 2021). However, the reality looks different: Medical professionals bear the responsibility for their decisions regarding the patient and thus are rather reluctant about using AI based systems - even though the AI could outperform them in image classification tasks. Most of the time decisions are based on personal experience, which was developed over a long period of time. This sentiment is reflected in the interview statements of medical professionals:

"One risk, I believe, is also that you hand over responsibility to the machine."

"The classic risk of simply relying on what the algorithm says."

"The doctor with his expert knowledge will always compare this with his knowledge and experience, is this correct, what is the probability, is this in the range?"

Modern DNN based image classifiers, such as the `XRV-DenseNet121-densenet121-res224-all` model from Cohen et al. (2020), can provide very good results in the prediction of pathologies. For example, the prediction accuracy for pneumonia is benchmarked as 86% (Cohen et al., 2021). The use of such model or comparative ones could benefit medical professionals in many ways as described by the interview partners:

"It [AI system] facilitates standardized findings in particular"

"It [AI system] might give you a little peace of mind that you haven't missed anything."

"I always think to myself that this is based on CT gray levels, i.e. on these density values, and I always think to myself that it makes sense that a com-

puter can distinguish these density levels better than my eyes."

The benefits of using a DNN based image classifier to support medical professionals in detection and diagnosis of diseases are clear. For users to leverage these benefits trust in such a system must be given, which cannot be generated by mere accuracy metrics (Samek et al., 2021). To overcome the hesitation of using AI in medical applications, a AI assessment system can be used to facilitate understanding of and trust in the algorithms. Stakeholders, such as practitioners or clinic managements, can use such a system to gain customized insights into the model and data prior to using it in everyday clinical practice.

## **2.4 User Analysis**

Trustworthiness and explainability of AI models only makes sense considering the potential user groups. For an assessment system that aims to explain AI models in the medical domain those user groups are: (1) Medical professionals, such as practitioners and clinic managements and (2) data scientists and AI researchers developing AI models. Naturally those two groups differ greatly from each other. While medical professionals have great expertise in various fields of examination, diagnosis and communication of pathologies, they also are expected to have little knowledge in computer sciences and machine learning. Data scientists on the other hand do have great knowledge of computer sciences, machine learning and neural network architectures, but lack the concrete medical expertise. Following the human-centered process the needs, requirements and wishes in regard to an AI assessment system of those user groups were analysed, mainly referencing the interviews from subsection 2.1.2 and the resulting thematic map (see Figure 2.1).

### **2.4.1 Medical professionals**

The user group of medical professionals is a very heterogenous one, which is to be expected from a professional field with many different specializations. This was also found out in the interviews. Surveying practitioners of different ages showed, that especially the younger ones, working in neuroradiology, are open towards using AI in their daily routine or that they are already using it. Great initiative was shown by two assistant



physicians, who also took courses on machine learning in the medical domain during their studies. Then again the older, but way more experienced surgeon has stated that he has much less contact with AI in clinical practice. All interviewed medical professionals showed interest in medical AI in research projects and were positive on the benefits of AI, especially computer vision tasks. The most cited benefits were the great ability of machine learning to identify pathologies in medical images, the take over of redundant tasks, the backup for diagnosis and the handling of computationally expensive tasks. The medical professionals were also wary and timid about using AI. This stance was stated to be mainly routed in the missing experience in using and trusting these systems. The black-box character of DNNs was stated to be a central issue: Not being able to re-trace the decisions of the AI and having to give away responsibility lead to trust and compliance issues, which was already stated by Ras et al. (2021). Depending on standard metrics was also stated to be insufficient, as the interviewed experts showed interest in the training data set and active comparison of the AI's results with their own experiences. While standard metrics, such as accuracy, sensitivity and specificity were important to the interviewees, the critical evaluation of the results and the validation of the behavior were wished for by every one of them.

As Table 2.1 shows, all interviewees had a high affinity for AI interaction. This is a important aspect to consider, since it shows their tendency to actively engage in interaction with AI while also being interested in it. This fact explains that the physicians were so interested in the explainability and comprehensibility of AI models. The interviewees stated that the explanation of AI decision and therefore the understanding of the model is important to them. Also the training data and its quality was a very common topic amongst all participants. Interestingly it was also stated, that understanding and trusting the model is important to being able to propagate the knowledge and trust to fellow medical practitioners and also patients.

Even though the interest in the functionality of machine learning models was big, the medical practitioners admitted that they have little knowledge on this subject and are limited regarding understanding the technical complexities. However they also stated that there is ongoing collaboration with AI researchers and software engineers for research purposes.

### 2.4.2 Data scientists and AI researchers

This potential group of AI assessment system users stand in great contrast to the previously mentioned one. Data scientists and AI researchers have a good understanding of the complexities and inner workings of machine learning algorithms. Therefore the requirements and needs of this user group are expected to be very different from the medical professionals. As Table 2.1 shows, unfortunately only one AI researcher could be interviewed during the analysis.

The interviewee stated experience with many kinds of neural networks, while also being familiar with clustering, featuring and interpretation tools. The perspective of AI researchers on interpretability and trustworthiness seems to be also quite different. Important aspects mentioned were: Performance metrics do not guarantee usability in real applications; separation of system results and system architecture; experimental validation; relations to developers; reviewing code. Understanding the complexities of such AI systems was a key aspect as stated by the interviewee. For this literature and study experience were mentioned to be crucial. Even some experimentation with heatmap-based explanation tools were used to understand AI models better.

While data scientists and AI researcher are different to medical professionals in their expertise, some overlap was found in the interviews: The interviewee stated to generate trust by doing exemplary input-output experiments, screening the training data set and reviewing own expectations. Another common topic was the insufficiency of standard metrics for assessing algorithm performance.

An explicit topic was the use of local explanations. The interviewee stated interest in local explanations as they are needed for improving their own understanding and for publications as proof that an algorithm works. Global explanations were not distinguished from local explanations by the interview partner, since the goal seemed to be the same: Determining if a model has weaknesses and to what it can be safely applied. Generating a benchmark for comparability of models to enable better adoption was wished for. Furthermore it was stated that theory should be researched further for understanding in addition to empiricism, which is also stated by Google (2021):

"When is an explanation really meaningful? Explaining everything is difficult, but finding out when explanation should be given."

## 2.5 Conclusion on the Analysis

While the use of DNN based image classifiers for medical applications has many benefits, actual adoption is impeded by the black box character of such systems. The potential users, such as medical practitioners have trust and compliance issues. Even though the users see the immediate benefits of such AI based systems, especially in computer vision tasks, the issue with handing over responsibility to a system they do not understand prevails.

Insufficient standard metrics shall be supplemented with more interactive explanations with a focus on the comprehensibility of complex AI models. Promoting the formation of an appropriate mental model and therefore trust in the abilities of such systems is a key aspect which was identified by the analysis. The use of a priori explanations via an assessment system where the users can experiment with different AI models in a protected environment covers many requirements of the users: Screening the training data, exploring model strengths and limitations, analyzing visual explanations for images and doing input-output experiments. These are the core requirements for an assessment system to increase explainability and trustworthiness of AI in medical, image-based applications. Other relevant findings suggest that such an assessment system needs to actively consider the intention of the user, since it can vary greatly depending on the person's background: Medical professionals with low expertise in machine learning may need to have a more guided user experience, while experts on the subject of machine learning may prefer a more open interaction style. Furthermore it is conceivable that statistical clustering, based on (training) metadata distributions can improve the explanation satisfaction by offering a balanced access to huge datasets in a way that is not susceptible to biases.

## 3 Conception

The conception of the AI assessment system follows from the requirements specified in the analysis. Based on the thesis objectives and user needs, functionalities have been derived. Core aspects to be adopted from the analysis are interactive exploration of data, visual explanation of attribution, comparative explanations, input-output experiments and interaction guidance. Before diving into the details of functional conception (section 3.3), interaction design (section 3.5), and system architecture (section 3.4), an overview of the conceptual approach (section 3.1) and foundational use cases (section 3.2) will be given.

### 3.1 Conceptual Approach

Based on chapter 2 and the primary objectives, the conception follows the already known design process. To begin with, building upon the previously gathered information, a functional specification was created. This specification relies heavily on the thematic analysis of the interviews, which is showcased in Figure 2.1. The first step of creating the functional specification was to identify common use cases for an AI assessment system which can be used by medical professionals. The specification defines formal tasks, sub-tasks and required capabilities for those use cases. The formalized functionalities were further used as the foundation for an interdependency analysis, which should highlight coactive human-computer-interaction design patterns (Johnson et al., 2014). Having the functionalities defined and set allows for conception of interaction and interface design, accompanied by the technical system architecture. The design concepts were created in a way that heavily referenced Google (2021) and Clearbox AI (2021b). Having Control Room by Clearbox as a close reference allowed for the leveraging of their knowledge and expertise. Furthermore a design iteration was created by conducting an expert workshop on interaction design with colleagues from Clearbox and the University of Lübeck. The results from interdependency analysis, interaction dialogues and interaction flowcharts

were then realized in chapter 4.

## **3.2 Use Cases**

Two common use cases found throughout the user requirements are to be presented as an anchor for further conception and reference. The main difference in these use cases is the underlying user group and therefore the intention of interaction.

### **3.2.1 Understanding through Interaction**

A main use case emerges from chapter 2: Medical professionals who want to understand and trust machine learning algorithms through extensive interaction with the training data, visual explanations and comparisons before actually using the system in their daily clinical life. Medical practitioners or clinic managements are therefore enabled to form appropriate expectations and mental model of the model's capabilities and performance, which helps them adopting the model and propagating knowledge and trust to professional peers and patients.

### **3.2.2 Comparison of Models**

An additional use case can be conceived, which revolves around users with a better understanding of machine learning: The interactive comparison of different AI models to be used in the context of medical application development. Using an AI model assessment beyond standard metrics can facilitate better decisions in favor or against a specific machine learning model. The ease of use and high interactivity of such system enables specialized users to explore more intricate facets of DNNs. Combining standard metrics with data exploration, visual perturbation techniques and the ability to experiment freely with the model creates a sandbox environment for testing and comparing different machine learning models and data sets.

### 3.3 Functionalities

Interactive explanations which offer access to information about the training data and the model’s functionalities, strengths and limitations are the focus. Furthermore natural alternatives in the form of comparative explanations, as described by Cai et al. (2019), shall be supplemented to the presentation of image data. Considering the low expertise of medical professionals in machine learning topics, general explanations of system capabilities in textual form are expected to be beneficial. Additionally the ability to execute input-output experiments with data and the actual model were universally requested. Table 3.1 summarizes the specified functionalities. Furthermore these functionalities will be supplemented by visual explanation techniques. A research on different visualization techniques yielded many possible algorithms to further explain the ML model’s reasoning. The main resources for this were Adadi and Berrada (2018), Arrieta et al. (2019), Ras et al. (2021), Ribeiro et al. (2018), Samek et al. (2021). A wide selection of implementations for visual explanation techniques are available, ranging from perturbation-based to model intrinsic methods as described by Ras et al. (2021). From this lot of techniques, three were found to be particularly interesting based on their features. Table 3.2 shows the selections and the main properties of those. Moreover subsection 3.3.1 further characterizes all explanation methods that are thought to be suitable for the assessment system application.

The functionalities, more specifically tasks, as defined in Table 3.1 were subject to an interdependency analysis. The goal of the analysis was to define sub-tasks and capabilities required for those, which give insights into the mode of interaction between computer and user. Table 3.3 showcases the key aspects of the analysis in form of an interdependency analysis table as conceived by Johnson et al. (2014). The table makes it clear, that the human interacting with the system is highly dependent on the computer - this is no surprise in the context of an explanatory system, where the user seeks out information about a complex model. On the other hand the computer does not depend much on the human counterpart, because it has the prevalence of information, but the computer can still benefit from the human expertise in certain situations. Overall this highlights the importance of interaction design and system collegiality for an AI assessment system.

#	Functionality	Description
1	Browse training data for given class	The user is able to explore the whole dataset, which was used for training of the ML model. Additionally it is possible for the user to filter the data based on classification labels.
2	Show examples of false negative, false positive and low confidence	The user is able to explore training data for which the classification resulted in false negative, false positive or low classification confidence
3	Group data based on similarities	The user is presented with clustered training data that was algorithmically identified to be similar.
4	Show data that is very similar to data from another class	The user is presented with comparative explanations which showcase data points that are very similar to other data points but classified differently
5	Offer overview of general system capabilities	The user is presented with general information and metrics about the ML model in a written and structured way
6	Show written Explanations	The user is presented with written explanations about the system by leveraging text templates
7	Input-Output-Experiment	The user is able to feed the ML model with data and predict the models result. The model then also predicts a result, which is then compared with the user's prediction

Table 3.1: Functional Specification

Method	Type	Description
Occlusion	Perturbation-based	Replaces rectangular areas in input with baseline reference and computes difference in output; Most useful in models where pixels in contiguous regions are likely to be correlated
Anchors	Rule-based	Shows part of the input (super pixels) which are sufficient for the classifier to make the prediction; Builds on the shortcomings of LIME (Ribeiro et al., 2016)
Layerwise Relevance Propagation	Model intrinsic	Propagates the prediction backwards using purposely designed local propagation rules; allows for differentiation between positive and negative influence of input pixels to prediction

Table 3.2: Visual Explanation Methods

### 3.3.1 Explanation Techniques

Three groups of explanation techniques are created as possible ways to implement the required functionalities (Table 3.1). The groups are divided by their style of interaction and information deliverance. Most of the presented techniques have a direct mapping to the functionalities to be provided by the assessment system, especially *General Description*, *Metrics*, *Data Browsing* and *Experiment*. The visual explanation techniques though, do overlap significantly in their practicality. While they differ drastically in their mode of operation and technical background, they do cater to the same interaction: Showing image regions that are significant to the result of the AI. Because of this and the limited time and resource frame, only one of the three proposed visual explanation types will be implemented.

#### Textual

*General Description:* General descriptions of the system capabilities aim to explain the system on a level, that is accessible to machine learning laymen, such as medical professionals. As described by Google (2021) it is beneficial for building trust when the system capabilities are explained instead of the technology itself. This helps the user to build a better mental model, especially when dealing with hyper-complex structures, such as DNNs. The general descriptions shall contain a textual explanations of the model capabilities to ensure a good introduction and appropriate



Tasks	Sub-Tasks	Required Capabilities	Team Member Role Alternatives				Interpretation and ODP Requirements
			Alternative 1	Alternative 2	Performer	Support	
			Computer	Human	Human	Computer	
Browse train data for given class	Choosing class	Knowing classes					Either can choose the class. Assistance by the computer could improve the directability. The human may not know all classes thus requires
	Access to data	Having storage					Only the computer can perform this task
	Display of data	Modify interface					Only the computer can perform this task
Show examples of false pos. / neg. or low confidence	Find data with given characteristic	Filter data					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Display data	Modify interface					Only the computer can perform this task
Group data based on similarity	Choose characteristic	Know characteristics					Either can perform this task but would benefit in reliability from assistance. Thus directability is required.
	Find data with given characteristic	Filter data					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Display data	Modify interface					Only the computer can perform this task
	Choose class	Know classes					Either can choose the class. Assistance by the computer could improve the reliability of the human. The human may not know all classes thus requires directability.
	Find data with high similarity but different classification	Filter data					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Display data	Modify interface					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
Show data that is classified as one class but very similar to data from another class	Find data with correct classification	Filter data					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Display data	Modify interface					Only the computer can perform this task
							The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
Offer overview of general system capabilities	Translate system specifications for laymen	Having overview of specifications					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Map T1-T5 to text templates	Knowing T1-T5					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
	Structure interface based on generated templates	Modify interface					The computer could improve reliability by being supported by the human. Thus observability and directability is required. The human can only tediously perform this task and would require assistance.
Show written explanations via templates	Navigate interface	Access to interface					Only the computer can perform this task
	Generate experiment data set	Knowing whole data set					Only the computer can perform this task
	Display data from experiment data set	Modify interface					While the computer can do this task, it is targeted towards the user which needs assistance. Thus requiring observability and directability
Human predication of system result experiment	Predict classification result	Understand ML algorithm					Only the computer can perform this task
	Show correctness of prediction	Know ground truth					Only the computer can perform this task

Table 3.3: Interdependency Analysis Table

expectations.

*Metrics:* Standard metrics are also used to describe the machine learning model. The metrics used are *Accuracy, Precision, Recall & F1*. Those metrics were chosen, because they are often used to describe other processes and applications in the medical context and therefore should be familiar and interpretable by the user.

## **Interactive**

*Data Browsing:* The ability to browse the training data of a machine learning model was universally requested by the interviewed professionals. The browsing ability is extended by different filters for the specific functionality. The user shall be able to explore the training data based on the class of the image. Furthermore the data will be algorithmically grouped based on similarities to potentially expose patterns. Additionally the user shall be able to explore data points that belong to the edge cases of the models capabilities, such as false negative and false positives.

*Experiment:* Comparing the machine learning models predictions to the human expertise also was a key aspect of AI interaction in the medical domain as shown by the interviews. Therefore a input-output-experiment shall be implemented, where the user is able to test the AI against its own expertise.

## **Visual**

*Occlusion:* A perturbation based approach to compute attribution, involving replacing each contiguous rectangular region with a given baseline, and computing the difference in output. Occlusion is most useful in cases such as images, where pixels in a contiguous rectangular region are likely to be highly correlated (Facebook, 2021; Zeiler & Fergus, 2013).

*anchors:* The algorithm provides model-agnostic and human interpretable explanations suitable for classification models applied to images, text and tabular data. The idea behind anchors is to explain the behaviour of complex models with high-precision rules called anchors. These anchors are locally sufficient conditions to ensure a certain prediction with a high degree of confidence (Ribeiro et al., 2018).

*LRP*: The Layer-wise Relevance Propagation (LRP) algorithm explains a classifier’s prediction specific to a given data point by attributing (positive & negative) relevance scores to important components of the input by using the topology of the learned model itself (Lapuschkin et al., 2019).

Referencing the chapter 2, the main goal of a visual explanation shall be the validation of the AI model’s behavior. Therefore a simple technique, such as Occlusion, which only highlights image regions with a high importance to a result, is reasonable to implement. While LRP does have certain benefits because of its ability to assess positive and negative influences of pixels to the model output, it also comes with a high complexity that manifests as a lot of hyperparameter, making it hard to implement and use properly. Anchors work differently to the other two methods, since it is able to find a hyperpixel that is most influential to a AI’s classification. In the context of standardized medical images, that are already preprocessed in a certain way (e.g. X-ray images), the method loses its edge. The high similarity of images in medical binary classification tasks lessens the expressiveness of Anchors significantly.

### 3.4 System Architecture

The goal is to create an interactive software application, therefore a suitable system architecture has to be constructed to suite the needs of the users and the usage context. Although, implementing the functionalities from section 3.3 is possible in many different ways. It is possible to realize the assessment system as a classical, offline software application or by leveraging web based tool sets for a possibly distributed cloud solution. Also it is conceivable to implement the system on a middle ground of those two, by creating a software that is build to be ran locally in common web browsers. To stay hardware and software agnostic these three options will be shortly evaluated against each other based on the requirements set by the functionalities.

The common requirements are the ability to store machine learning models and training data for the assessment to be computed. In addition the user has to be presented with a graphical user interface (**GUI**) to interact with. Having these two components in a close relation can drastically reduce the overhead of implementing the communication between the computational and data storage component with the GUI component. On the other hand such a close relation in an offline system can significantly reduce the

flexibility of the implementation regarding GUI and interaction design. Furthermore a single offline application has to take many different execution environments (operating systems) into account, which might be a big downside depending on the actual context of usage. Separating the system into a multi-tier application allows for more modularity and freedom in choosing the actual implementation technology. A multi-tier web application allows for a very specialized choice of tools for the respective component at the cost of a higher complexity and implementation cost. Such web applications have the advantage of being relatively easy to transform into a local application without the need of hosting a server environment. This can be the middle ground between the offline local and the web based distributed application.

Referencing the usage context of the application it is not needed to implement a highly complex distributed application, although Clearbox has shown that it is very much possible to implement a robust cloud based solution. To reduce the scope of implementation for this thesis a middle ground is the most reasonable: Leveraging modern web based tools that are mostly environment agnostic to build a flexible application that could be ran in either the cloud or locally on a single machine.

### **3.5 Interaction Design**

The interaction design is a key aspect of human-computer-interaction, as it defines how the user will actually interact with the system and how information will be made accessible to the user. Considering the human factors in the design process is very important as described by Wickens et al. (2016) - for this builds upon the insights of the previous chapters, namely the definition of interaction (sub-)tasks and the interdependency analysis, which in turn are based on the general objectives and user needs as described in chapter 2.

The conception of functionalities and interaction design was the main topic of the previously mentioned expert workshop, which was conducted with colleagues from the University of Lübeck and Clearbox. The goal was to present, validate and discuss the scope of functionalities (based on the previous research and the user requirements) and the interaction design which utilizes scaffolding and guidance for the main user group. The workshop yielded good feedback on the scope of functionalities and the guidance idea. A main focus of the discussion was type of guidance which was then resolved to a semantic

signal manifested by an intention query.

A central consideration of the interaction design is to adapt the system to the abilities and needs of the actual users. Referencing subsection 2.1.2, a main user group has low expertise in machine learning, which in turn means special requirements for the interaction design of an AI assessment system. Therefore the design approach will revolve around a guided interaction version and a unguided interaction version: The guided interaction will leverage a more streamlined approach which facilitates the intentions of the user by asking and then presenting the respective functionality. Trigg (1988) already proposes local guidance of the user by the author of a system, by using intention queries to determine a suitable path through the content of an application. This mode of interaction aims to relieve the user of mental workload by scaffolding the application and thus avoiding the presentation of all functionalities, and therefore aiding the learning process for machine learning topics (Soloway et al., 1994). The other mode of interaction will be unguided, as in there will be no intention query and the user will be able to freely explore the whole lot of functionalities offered by the application, which is hypothesized to be beneficial for users with more expertise in machine learning. The baseline for both ways of interaction is the whole array of functionalities as specified in Table 3.1.

To further explore and concretize the interaction design two methods were applied: *Interaction Dialogues* and *Interaction Flowcharts*. Interaction dialogues aim to creatively explore different ways of implementing the functionalities as defined in section 3.3. Additionally they enable the exploration of other perspectives based on a natural interaction mode (spoken dialogue). The result is then the baseline for the interaction flowcharts, which specify the concrete flow of information in a standardized manner.

### 3.5.1 Interaction Dialogues

The idea of using interaction dialogues to creatively explore different ways of interacting with the assessment system came from the cooperation with Clearbox. A colleague specialized in building User Interaction and User Experience proposed this method to be used for developing the interaction design. Using dialogues as the mode of interaction and communication between human and computer allows for a very liberated design process. The goal was to explore different variations of interaction based on the functionalities as defined in Table 3.1. An example dialogue (with H for human and C for computer) for task 1 will be presented:

H: I would like to see your training data.  
C: Do you want to see all data or just data for a specific class?  
H: I want to only see data for class x.  
C: Here you go! Do you want to see data of another class, too?  
H: Yes please, but give me some time.  
C: Of course!

Using the dialogue technique allows for easy exploration of alternative information flows as shown by the next example:

H: I would like to see your training data.  
C: Here take a look!  
H: Wow, that is really a lot!  
C: Do you want to filter for a specific class?  
H: Yes, please show me only data for class x.  
C: There you go.  
H: Thank you, and now please show me all data for class y.  
C: Sure, here!

These examples clearly show different ways of interacting in order to accomplish the same task: Browsing the training data. This process was applied to all tasks (and sub-tasks) from Table 3.3 to gather a lot of different interaction variations, to be then used as a baseline for the following interaction flowcharts. The key takeaways from this process, was that there are various possibilities to realize an interaction. With multiple alternatives per task, some comparisons could be made: Often it seems beneficial for a streamlined interaction design, to present the user with a set of options from the beginning, instead of presenting everything and then reducing the amount of information. Furthermore situations with exhaustive searches can be avoided by presenting the user a limited amount of information. Most tasks had two to three alternatives which were compared against each other in order to find the best dialogue, which was then chosen to be the baseline for the standardized flowcharts.

### 3.5.2 Interaction Flowcharts

Building on the previous chapters the possible human-computer-interactions were formalized into flowcharts. The type of flowchart is defined in *DIN 66001* (Hering, 1984).

The flowcharts are essential as a reference for the implementation, as they define the details of the information flow between the two parties. The goal is to have interactions that have a clear start and end point, with no dead ends - leveraging flowcharts for this allows for an easy validation of these goals. Another goal was to separate the application into smaller, more manageable pieces, each defined by its own flowchart. Figure 3.1 shows a flowchart that defines the flow of interaction for the process of browsing classified images (task 1 from Table 3.1), with the background of the presented interaction dialogue. For each of the tasks defined in Table 3.1 and Table 3.3 such a flowchart was developed as seen in Appendix C: Interaction Flowcharts.

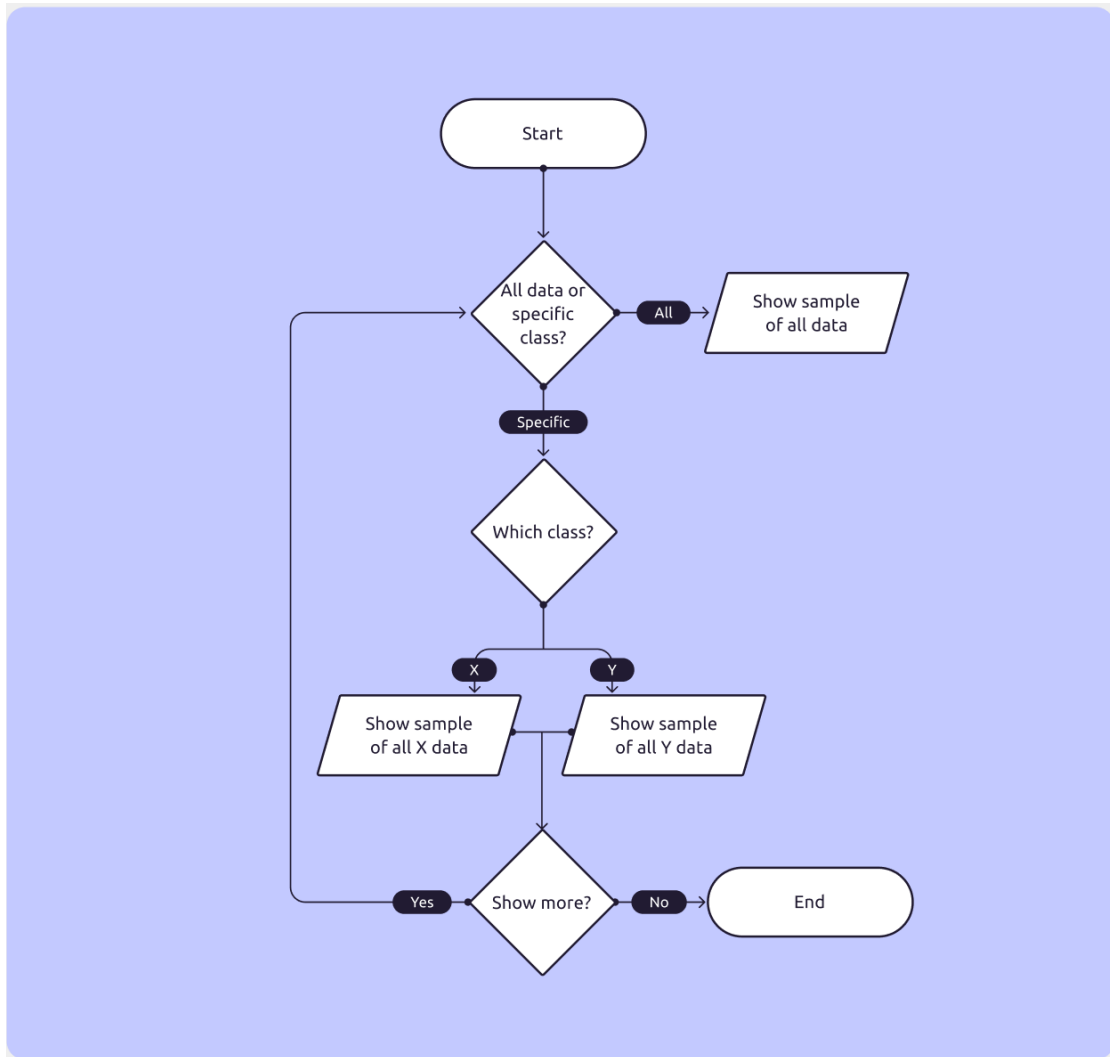


Figure 3.1: Flowchart - Browse Training Data for a given Class

## 3.6 Interface Design

Building on the functional specification and the interaction design an interface design was developed to encompass the whole array of functionality into a single application. Similar to the flowcharts the application interface will be split up into single elements of interaction as defined by the tasks and interaction flowcharts. This separation allows for a better overview and a more flexible layout. Additionally inspiration was drawn from the state-of-the-art application from Clearbox as seen in section 1.2, where a similar approach was chosen. The concept of splitting the application into smaller pieces also facilitates the usability of the whole application, as the user will not be overburdened with all functionalities simultaneously. Instead the user will be able to choose which functionality he wants to utilize.



## Nach der ersten Iteration: STOP

Nachdem Sie die erste Iteration abgeschlossen haben, nehmen Sie das Blatt Papier, auf dem Sie vor/während der Analyse Ihre Lösungsidee(n) festgehalten haben, wieder heraus. Vergleichen Sie Ihre ursprüngliche Idee mit der ersten Iteration.

### **Falls sich Ihre erste Iteration sich stark von der ersten Idee unterscheidet:**

Prima. Sie haben während der Analyse dazu gelernt und den Nutzungskontext besser verstanden. Ohne die Analyse und die Verwendung dieser Informationen in der Konzeption hätten Sie das nicht machen können.

**Falls Ihre erste Iteration Ihrer ersten Idee sehr ähnlich ist:** Entweder Sie kannten sich schon vor der Analyse mit dem Themengebiet sehr gut aus — oder (und das ist wahrscheinlicher) — sie hängen zu stark an Ihrer ersten Idee und hören der Zielgruppe nicht zu. Auch falls Sie selbst zur Zielgruppe gehören (z. B. eine Anwendung für Studierende), Sie sind nicht "alle Nutzer". Nutzer unterscheiden sich üblicherweise. Entsprechend wirklich am in sich gehen — haben Sie aus der Analyse wirklich nichts dazu gelernt? Was das Problem (oder Sie selbst) wirklich so trivial? Das Schöne an kreativen Prozessen ist ja, dass man iterativ besser werden kann und auch auf Ideen kommen kann, auf die man vorher nicht gekommen wäre. Die Chance sollten Sie nutzen.

BTW, dieser Hinweis heißt nicht, dass Sie komplett naiv an Ihre Gestaltung herangehen sollten, ohne sich vorher Gedanken zu machen. Aber, wenn Sie eine Analyse wirklich ernst nehmen, dann sollte die Ihnen Sachverhalte aufzeigen, die man als Außen-stehender nicht sieht. Und Sie sollten auch in der Konzeption basierend auf diesen Informationen Lösungen entwickeln, die über die ersten simplen Ideen hinausgehen (vgl. confirmation bias). Die neu und nützlich sind.

### **3.7 Conclusion on the Conception**

Wie auch bei der Analyse am Ende der Konzeption ein kurzes Fazit um den Entwicklungsprozess zusammenzufassen und begründen, was die erfolgversprechendste Lösung (höchste Gebrauchstauglichkeit in der formativen Evaluation!) für die Realisierung ist.

Text ...

## 4 Implementation

Beschreiben Sie, wie Sie das Projekt konkret realisiert haben, mit dem Ziel, anderen (Medien-)Informatikern zu erlauben, Ihre Anwendung weiter zu entwickeln.

**Test:** Sie nehmen einen Kommilitonen, geben ihm dieses Kapitel und bitten ihm eine Funktion hinzuzufügen oder zu verändern. Wenn er das kann, prima. Wenn nicht, besser schreiben oder bessere Kommilitonen suchen.

Verweisen Sie zu Beginn auf die erfolgreichste Lösung aus der Konzeption. Wie in der Konzeption bieten sich Unterkapitel mit Systemarchitektur und Interface-Design an — jetzt allerdings mit konkreten Angaben, welche Programme / Frameworks Sie verwenden, und wie Sie das Interface konkret umsetzen.

Geben Sie zuerst einen allgemeinen Überblick und werden dann konkreter. Als wenn Sie in eine Weltkarte reinzoomen. Erst mal sagen, wie die Welt aufgebaut ist (Kontinente), dann auf Kontinent mit Ländern zoomen, dann exemplarisch mal auf ein Land. Leser braucht ein gutes mentales Modell vom Aufbau und den Funktionen, um zu verstehen, wie es technisch umgesetzt wurde.

**Begründen Sie Ihre Entscheidungen linear:** Z.B.

1. "das sind die Anforderungen aus der Analyse/bisheriger Konzeption"
2. "Programmiersprache / System / etc. x, y, und z erfüllen diese Anforderungen"
3. "relevante Kriterien sind a, b, c und d (z. B. Verbreitung, Community, Weiterentwicklung, Preis)"
4. "Programmiersprache / System / etc. x, y, und z schneiden da so und so ab, x ist insgesamt am besten"
5. "Programmiersprache / System / SDK / etc. x wird verwendet". Eine Argumen-

tation à la  $A \Rightarrow B \Rightarrow C \Rightarrow D \Rightarrow E$  ist nachvollziehbarer als wir nehmen E, weil  $A \Rightarrow C$  woraus D folgt, wegen B.

Weiterer Grund: Wenn Sie zuerst die konkrete Software sagen, dann fangen Personen direkt an, die Entscheidung zu hinterfragen (weil sie z. B. eine andere bevorzugen, gibt da genug Religionskriege). Wenn Sie linear argumentieren gehen diese Personen eher bei jedem Schritt mit und enden dann bei der von Ihnen verwendeten Software (sofern sie bei den Auswahlkriterien und der Bewertung mitgehen).

**Nutzen Sie den Datenträger im Anhang der Arbeit:** Insbesondere in den Programmcode können Sie viel auslagern. In der Arbeit muss der Leser aber die Struktur/den Aufbau Ihres Programms verstehen sowie die Logik dahinter. Und er muss wissen, dass es die Erläuterungen im Programmcode gibt und wo er diese findet. Entsprechend die Struktur (Dateien/Klassen) deutlichen machen und Verweise auf relevanten Dateien.

Text ...

## 4.1 System Architecture Implementation

vgl. Konzeption, jetzt aber wie und womit es konkret umgesetzt wurde (u.U. bieten sich UML-Diagramme an)

Text ...

## 4.2 Interface Implementation

vgl. Konzeption, jetzt aber wie und womit es konkret umgesetzt wurde

Text ...

## 4.3 Conclusion on the Implementation

Kurzes Fazit, das u.a. die Frage beantwortet, was technisch konkret umgesetzt wurde und was z. B. aus der Konzeption übrig geblieben ist und warum.

Text ...

## 5 Dialogue Samples

Verdeutlichen Sie die Funktionsweise Ihrer Entwicklung bei einer typischen Bedienung (z. B. wie in einem Anwendungsbeispiel / Use Case beschrieben — auf den können Sie sich ja beziehen).

Die Abbildungen müssen im Text vorher erläutert sein und einen Eindruck geben, wie die Entwicklung konkret bedient wird bzw. was sie kann.

**Das ist das, was bleibt:** Diese Dialogbeispiele sind das einzige, was in ein paar Jahren von Ihrer Anwendung noch sichtbar ist. Dann ist entweder der Datenträger verschwunden oder beschädigt oder die notwendige Hard- und Software ist nicht mehr lauffähig. Geben Sie dem Leser entsprechend einen guten Einblick in das, was Sie tatsächlich realisiert haben.

**Jetzt ein Video aufnehmen:** Schalten Sie den Screenrecorder auf dem Computer (not-falls: QuickTime) oder Smartphone (kann das OS) an und nehmen Sie die typischen Interaktionen einmal auf. Das ist Ihr "Plan B", falls (oft: wenn) im Kolloquium die App nicht bedient werden kann. Das können Sie auch gut auf DVD brennen um Lesern die Möglichkeit geben, sich die Interaktion anzusehen (in der Arbeit darauf hinweisen!). Macht sich auch gut auf Websites (insbesondere dem eigenen Portfolio).

Text ...

## 6 Summative Evaluation

Geben Sie zu Beginn der Evaluation einen kurzen Überblick über Ihr Vorgehen. Dazu reichen meist die Zwischenüberschriften mit ein oder zwei Sätzen, was Sie konkret gemacht haben. Also nicht "In Design wird das Design beschrieben" sondern "Das experimentelle Vorgehen wird im Abschnitt Design dargestellt".

Text ...

### 6.1 Goal

Die summative Evaluation ist eine abschließende Bewertung Ihrer Entwicklung. Ziel ist, unter dem Strich zu sehen, wie gebrauchstauglich Ihr System ist (nicht mehr eine iterative Verbesserung wie in der formativen Evaluation der Konzeption). Da-für müssen Sie klare Kriterien ableiten, was eine "gute" bzw. "schlechte" Bewertung nach sich ziehen würde. Meist sind das die klassischen Gebrauchstauglichkeitskriterien (Effektivität, Effizienz, Erlernbarkeit, Zufriedenstellung), wobei diese über das Ziel Ihrer Anwendung konkretisiert werden (Effektivität bei einer Lernapp ist konkret gemessen etwas anderes als Effektivität bei einem digitalen Depressionstagebuch).

Hier verdeutlichen Sie entsprechend, welche Fragen die Evaluation beantworten soll.

Text ...

### 6.2 Methods

Im Methodenteil zeigen Sie, was wie evaluiert wurde. Der Methodenteil muss anderen Entwicklern die Möglichkeit geben, Ihr Evaluationsvorgehen zu wiederholen um Ihre Ergebnisse zu überprüfen.

Text ...

### **6.2.1 Design**

Kurze Beschreibung des Versuchs- oder Evaluationsdesigns, dass man das Vorgehen einordnen kann. Also z. B. "es wurde ein Usability Test durchgeführt", oder "es wurde ein Experiment mit between-subjects design durchgeführt, bei dem die Kontrollgruppe die bisherige App verwendet hat und die Experimentalgruppe die neu entwickelte App".

Text ...

### **6.2.2 Participants**

Kurze Beschreibung der Teilnehmer mit relevanten Angaben. In jedem Fall die Anzahl, oft noch Geschlecht, Alter, Beruf, Vorerfahrung, etc. Bei weniger als zehn Teilnehmern bietet sich eine Tabelle zur schnellen Übersicht an. Verweisen Sie bei individuellen Ergebnissen (z.B. Zitaten aus Fragebögen oder Interviews) auf die Teilnehmer-Nummer.

Achtung: Niemals die Namen der Teilnehmer erwähnen! Die Teilnehmer stehen stellvertretend für die Zielgruppe. Wer sie konkret sind ist irrelevant. Begründen Sie, warum Sie diese Personen ausgewählt haben (spiegeln die Nutzergruppe gut wider) und wo/wie Sie diese rekrutiert haben.

Text ...

### **6.2.3 Setting and Instruments**

Beschreiben Sie die notwendigen Materialien bei der Evaluation. Dazu gehört — mit Überschriften klar ausgewiesen — das Setting (wo wurde die Evaluation durchgeführt),



Ihre Entwicklung (Verweis auf Dialogbeispiele), und Ihre Erhebungsmethoden (Fragebögen, Interviewleitfäden, etc.).

Falls Sie etablierte Fragebögen verwenden (z.B. ATI) reicht die entsprechende Zitation mit einer kurzen Beschreibung. Bei längeren Fragebögen oder Interviewleitfäden nennen Sie kurz die Abschnitte (z.B. soziodemographische Daten, Technikerfahrung, etc.) und verweisen Sie auf die vollständigen Fragebögen im Anhang.

**ACHTUNG:** Zeitliche Reihenfolge ist hier egal. Hier geht es nach Gliederungspunkten wie Instrumente (Fragebögen, Interviews, etc.). Die zeitliche Reihenfolge wird in der Prozedur dargestellt.

### **Setting**

Text ...

### **Verwendete Anwendung**

Text ...

### **Fragebögen**

Text ...

## **6.2.4 Procedure**

Beschreiben Sie chronologisch den Ablauf der Evaluation, von der Begrüßung bis zur Verabschiedung. Verweisen Sie dabei auf die anderen Abschnitte (v.a. Setting und Instrumente) und führen Sie nichts Neues mehr ein. Dieser Abschnitt ist der einzige Abschnitt, in dem Sie die zeitliche Reihenfolge klar einhalten müssen, alle anderen sind inhaltlich strukturiert.

Text ...

Nach dem Lesen der Methode muss deutlich geworden sein, wie Sie Ihre Evaluationsfragen messbar gemacht haben. Wie haben Sie z.B. Benutzerzufriedenheit oder Effizienz

gemessen? Die Leser müssen sich aufgrund des Methodenteils in die Lage der Teilnehmer versetzen können und ein mentales Modell Ihrer Evaluation bilden können.

## 6.3 Results

In den Ergebnissen zeigen Sie wie die Ergebnisse analysiert wurden um Ihre Evaluationsfragen zu beantworten. Nicht einfach die Daten auflisten, sondern stellen Sie die Ergebnisse strukturiert dar und betonen Sie die wichtigen Aspekte. Gliedern Sie die Ergebnisse nach Ihren Forschungsfragen / Fragestellungen (nicht zeitlich oder nach Erhebungsmethoden wie Fragebögen vs. Beobachtung). Zu Beginn (falls relevant) sollten Sie überprüfen, ob die Anwendung auch wirklich so verwendet wurde, wie sie verwendet werden sollte (manipulation check). Haben die Personen also z. B. wirklich die Aufgaben mit der App gelöst oder haben sie die App schnell beiseite gelegt.

Stellen Sie die Befunde / Ergebnisse von Analysen / Evaluationen / etc. immer so neutral und so objektiv wie möglich dar — ohne Ihre subjektive Interpretation oder Bewertung. Also keine Begriffe wie "lediglich", "nur", "könnte / würde / sollte / etc." oder Bewertungen wie "hat gut / nicht gut geklappt". Diese Bewertungen gehört in die Diskussion.

Überlegen Sie sich mit welchen Tabellen und Abbildungen Sie die Ergebnisse gut darstellen können. Bei aggregierten Messwerten (auf mindestens Intervallskalenniveau) immer Mittelwerte (M), Standardabweichungen (SD) und die Anzahl der Messdaten (Personen, n) angeben. Bei ordinalskalierten Daten entsprechend Median, etc. (ja, Statistik war wichtig).

Statistische Tests korrekt angeben (siehe z.B. Pallant, 2010).

Pallant, J. (2007). SPSS Survival Manual (3rd ed.). Open University Press.

Abbildungen müssen in sich verständlich sein (was abgebildet ist). Das heißt, die Achsen eindeutig beschriften, Skala (z.B. Likert-Skala von 1 starke Ablehnung bis 7 starke Zustimmung) in die Legende. 3D-Graphiken vermeiden — diese bieten oft keinen Mehrwert (vgl. Field, 2016).

Field, A. (2016). An Adventure in Statistics. Sage.

Am Ende des Ergebnis-Abschnitts muss deutlich geworden sein, wie Ihre Entwicklung von den Teilnehmenden eingesetzt wurde (hoffentlich wie geplant), was die Hauptergebnisse waren, sofern aufgrund der Stichprobengröße möglich welche Werte sich statistisch signifikant voneinander unterscheiden und was die statistischen Ergebnisse in den Variablen bedeuten (z. B. positive Korrelation zwischen A und B, dass Personen, die A besser bewertet haben auch B besser bewertet haben; aber keine Bewertung ob das gut oder schlecht ist). Falls Sie konkrete Ziele hatten (z. B. "SUS-Wert von x") dann sagen Sie, ob dieses Ziel erreicht wurde oder nicht (das ist keine Wertung, die in die Diskussion gehören würde, sondern ein größer, gleich oder kleiner was eindeutig ist).

Text ...

## 6.4 Discussion

In der Diskussion erklären und interpretieren Sie die Ergebnisse. Welche Schlussfolgerungen ziehen Sie daraus? Was sind die praktischen Konsequenzen für die (weitere) Entwicklung? Hier dürfen Sie selbst die Ergebnisse bewerten — auf Basis von einer kritischen Reflektion. In der Diskussion keine neuen Ergebnisse aus der Analyse / Evaluation / etc. einführen. Die Beweisaufnahme ist mit Ende des Ergebnisteils abgeschlossen. Es geht hier auch nicht um eine Mystery-Geschichte mit Spannungsbogen, sondern um klar nachvollziehbare Argumente. Neue Informationen aus der Literatur verwenden um die (v.a. überraschende) Ergebnisse zu interpretieren ist dagegen möglich.

Text ...

## 6.5 Conclusion on the Evaluation

Fassen Sie die Evaluation kurz zusammen — insbesondere was die zentralen Ergebnisse waren. Unterm Strich: Wie gut hat's geklappt?

Text ...

## 7 Summary and Outlook

Kurze Einführung, was in den folgenden Unterkapiteln behandelt wird.

Text ...

### 7.1 Summary

Fassen Sie die zentralen Schritte und Ergebnisse Ihrer Arbeit kurz zusammen. Personen mit wenig Zeit müssen aus dieser Darstellung die Kernpunkte Ihrer Arbeit mitnehmen und Ihren Arbeitsaufwand und Erfolg bewerten können.

Ist ähnlich wie die Zusammenfassung zu Beginn der Arbeit, aber etwas länger (1 bis maximal 2 Seiten) mit Verweisen auf die entsprechenden Kapitel/Abschnitte und Sie können beim Leser etwas mehr voraussetzen (hat es gelesen oder kann wegen den Verweisen direkt dahin springen).

Text ...

### 7.2 Outstanding Issues

**Offene Punkte = Versprochene aber nicht umgesetzte Punkte:** Falls Schritte explizit geplant wurden (Exposé! Pflichtenheft!), aber nicht realisiert werden konnten, dann diese hier klar darstellen und diskutieren.

Mögliche Features, die Sie nicht vor Beginn versprochen haben, gehören in den Ausblick.

Text ...

## 7.3 Outlook

Ideen, welche weiteren Entwicklungen oder Untersuchungen folgen sollten, oder was man noch umsetzen könnte, gehören in den Ausblick.

Versprochene aber nicht umgesetzte Elemente in die Offenen Punkte.

Bitte keine Allgemeinheiten ("können noch Features hinzugefügt werden" oder "könnte besser evaluiert werden") sondern konkrete Beschreibungen und Begründungen der Relevanz dieser Schritte.

Text ...

## 7.4 Final Conclusion

Die Arbeit, die Ergebnisse und weitere mögliche Schritte kurz kritisch (ehrlich und konstruktiv, aber nicht selbstkreuzigend) reflektieren und positiv enden. Maximal eine halbe bis 3/4 Seite. Ist kurz und hier können Sie von der Arbeit zurücktreten und auch den Leser aus dem Text ziehen.

Das ist nur zum Test: Ford (2011) Apache Software Foundation (2010)

Text ...

# List of Figures

1.1	AI Control Room - Model Assessment Overview with Standard Metrics . . . . .	5
1.2	AI Control Room - Precision-Recall and Calibration Graphs . . . . .	6
1.3	AI Control Room - Model String Points and Limitations . . . . .	6
1.4	AI Control Room - Interpretability Assessment . . . . .	7
1.5	AI Control Room - Example Data . . . . .	7
1.6	AI Control Room - Prediction Explanation for Examples Data . . . . .	7
1.7	Human-centered Design Process ( <i>DIN EN ISO 9241-210</i> , 2011) . . . . .	9
2.1	Thematic Mind Map . . . . .	14
3.1	Flowchart - Browse Training Data for a given Class . . . . .	33
7.1	Flowchart - Browse Training Data for a given Class . . . . .	71
7.2	Flowchart - Show Examples of false positive / negative or low confidence .	72
7.3	Flowchart - Show Similarities . . . . .	73
7.4	Flowchart - Grouping of Data based on Similarities . . . . .	74
7.5	Flowchart - Overview of General System Capabilities . . . . .	75
7.6	Flowchart - Show Written Explanations via Templates . . . . .	76
7.7	Flowchart - Input-Output Experiment . . . . .	77

# List of Tables

2.1	Interview Participants . . . . .	12
2.2	Interview Topics . . . . .	13
3.1	Functional Specification . . . . .	25
3.2	Visual Explanation Methods . . . . .	26
3.3	Interdependency Analysis Table . . . . .	27

# Sources

## References

- Adadi, A., & Berrada, M. (2018). Peeking inside the black-box: A survey on explainable artificial intelligence (xai). *IEEE Access*, 6, 52138–52160. <https://doi.org/10.1109/ACCESS.2018.2870052>
- Alley, M. (1996). *The Craft of Scientific Writing* (Vol. 3). Springer.
- Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2019). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *arXiv:1910.10045 [cs]* arxiv 1910.10045. Retrieved May 19, 2021, from <http://arxiv.org/abs/1910.10045>
- Braun, V., & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101. <https://doi.org/10.1191/1478088706qp063oa>
- Cai, C. J., Jongejan, J., & Holbrook, J. (2019, March 17). The effects of example-based explanations in a machine learning interface, In *Proceedings of the 24th international conference on intelligent user interfaces*, Marina del Ray, California, Association for Computing Machinery. <https://doi.org/10.1145/3301275.3302289>
- Chiou, E. K., & Lee, J. D. (2021). Trusting automation: Designing for responsivity and resilience. *Human Factors*, 00187208211009995. <https://doi.org/10.1177/00187208211009995>
- Clearbox AI. (2021a). *Clearbox AI Model Assessment* (Whitepaper). Retrieved April 2021, from [https://clearbox.ai/pdf/ClearboxAI\\_Technical\\_Whitepaper.pdf](https://clearbox.ai/pdf/ClearboxAI_Technical_Whitepaper.pdf)
- Cohen, J. P., Hashir, M., Brooks, R., & Bertrand, H. (2020). On the limits of cross-domain generalization in automated x-ray prediction. *arXiv:2002.02497 [cs, eess, q-bio, stat]* arxiv 2002.02497. Retrieved October 25, 2021, from <http://arxiv.org/abs/2002.02497>



- DIN EN ISO 9241-210: Ergonomie der Mensch-System-Interaktion - Teil 210: Prozess zur Gestaltung gebrauchstauglicher interaktiver Systeme.* (2011). DIN Deutsches Institut für Normung e. V. Beuth Verlag.
- European Commission. (2020). *On Artificial Intelligence - A European approach to excellence and trust* (Whitepaper). Retrieved September 2021, from [https://ec.europa.eu/info/sites/default/files/commission-white-paper-artificial-intelligence-feb2020\\_en.pdf](https://ec.europa.eu/info/sites/default/files/commission-white-paper-artificial-intelligence-feb2020_en.pdf)
- Franke, T., Attig, C., & Wessel, D. (2019). A personal resource for technology interaction: Development and validation of the affinity for technology interaction (ATI) scale. *International Journal of Human-Computer Interaction*, 35(6), 456–467. <https://doi.org/10.1080/10447318.2018.1456150>
- Gordon, M. L., Zhou, K., Patel, K., Hashimoto, T., & Bernstein, M. S. (2021, May 6). The disagreement deconvolution: Bringing machine learning performance metrics in line with reality, In *Proceedings of the 2021 CHI conference on human factors in computing systems*. CHI '21: CHI Conference on Human Factors in Computing Systems, Yokohama Japan, ACM. <https://doi.org/10.1145/3411764.3445423>
- Hering, E. (1984). Programmablaufplan nach DIN 66001. In E. Hering (Ed.), *Software-Engineering: Mit 77 Bildern und 22 Übungsaufgaben* (pp. 26–34). Wiesbaden, Vieweg+Teubner Verlag. [https://doi.org/10.1007/978-3-322-86222-8\\_4](https://doi.org/10.1007/978-3-322-86222-8_4)
- Hoffman, R. R., Mueller, S. T., Klein, G., & Litman, J. (2019). Metrics for explainable AI: Challenges and prospects. *arXiv:1812.04608 [cs]* arxiv 1812.04608. Retrieved May 19, 2021, from <http://arxiv.org/abs/1812.04608>
- Johnson, M., Bradshaw, J. M., Feltovich, P. J., Jonker, C. M., van Riemsdijk, M. B., & Sierhuis, M. (2014). Coactive design: Designing support for interdependence in joint activity. *Journal of Human-Robot Interaction*, 3(1), 43–69. <https://doi.org/10.5898/JHRI.3.1.Johnson>
- Keane, M. T., & Kenny, E. M. (2019). How case based reasoning explained neural networks: An XAI survey of post-hoc explanation-by-example in ANN-CBR twins. *arXiv:1905.07186 [cs]*, 11680 arxiv 1905.07186, 155–171. [https://doi.org/10.1007/978-3-030-29249-2\\_11](https://doi.org/10.1007/978-3-030-29249-2_11)
- Knapič, S., Malhi, A., Saluja, R., & Främling, K. (2021). Explainable artificial intelligence for human decision-support system in medical domain. *arXiv:2105.02357 [cs]* arxiv 2105.02357. Retrieved June 11, 2021, from <http://arxiv.org/abs/2105.02357>

- Lapuschkin, S., Binder, A., Montavon, G., Müller, K.-R., & Samek, W. (2016). The lrp toolbox for artificial neural networks. *Journal of Machine Learning Research*, 17(114), 1–5. <http://jmlr.org/papers/v17/15-618.html>
- Lapuschkin, S., Wäldchen, S., Binder, A., Montavon, G., Samek, W., & Müller, K.-R. (2019). Unmasking clever hans predictors and assessing what machines really learn. *Nature Communications*, 10(1), 1096. <https://doi.org/10.1038/s41467-019-08987-4>
- Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable AI. *arXiv:1902.01876 [cs]*arxiv 1902.01876. Retrieved May 19, 2021, from <http://arxiv.org/abs/1902.01876>
- Ras, G., van Gerven, M., & Haselager, P. (2018). Explanation methods in deep learning: Users, values, concerns and challenges. *arXiv:1803.07517 [cs, stat]*arxiv 1803.07517. Retrieved May 19, 2021, from <http://arxiv.org/abs/1803.07517>
- Ras, G., Xie, N., van Gerven, M., & Doran, D. (2021). Explainable deep learning: A field guide for the uninitiated. *arXiv:2004.14545 [cs, stat]*arxiv 2004.14545. Retrieved October 6, 2021, from <http://arxiv.org/abs/2004.14545>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "why should i trust you?": Explaining the predictions of any classifier. *arXiv:1602.04938 [cs, stat]*arxiv 1602.04938. Retrieved May 19, 2021, from <http://arxiv.org/abs/1602.04938>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2018). Anchors: High-precision model-agnostic explanations. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1). Retrieved June 24, 2021, from <https://ojs.aaai.org/index.php/AAAI/article/view/11491>
- Samek, W., Montavon, G., Lapuschkin, S., Anders, C. J., & Müller, K.-R. (2021). Explaining deep neural networks and beyond: A review of methods and applications. *Proceedings of the IEEE*, 109(3), 247–278. <https://doi.org/10.1109/JPROC.2021.3060483>
- Soloway, E., Guzdial, M., & Hay, K. E. (1994). Learner-centered design: The challenge for HCI in the 21st century. *interactions*, 1(2), 36–48.
- Trigg, R. H. (1988). Guided tours and tablespots: Tools for communicating in a hypertext environment. *ACM Transactions on Information Systems (TOIS)*, 6(4), 398–414.
- Wickens, C. D., Helton, W. S., Hollands, J. G., & Banbury, S. (2016). *Engineering Psychology and Human Performance*. Routledge.

Zeiler, M. D., & Fergus, R. (2013). Visualizing and understanding convolutional networks. *arXiv:1311.2901 [cs]* arxiv 1311.2901. Retrieved June 10, 2021, from <http://arxiv.org/abs/1311.2901>

## Websites

Clearbox AI. (2021b, October). *Manage AI models with confidence*. <https://clearbox.ai/>

CoCoAI. (2021, September). *Cooperative and communicating AI methods for medical image-guided diagnostics - A research project at the University of Lübeck*. <https://cocoai.uni-luebeck.de>

Cohen, J. P., Viviano, J., Morrison, P., Brooks, R., Hashir, M., & Bertrand, H. (2021, October). *TorchXRayVision: A library of chest X-ray datasets and models*. <https://github.com/mlmed/torchxrayvision>

Corporation for Digital Scholarship. (2021, July). *Your personal research assistant*. <https://www.zotero.org/>

European Commision. (2021, March). *Ethics guidelines for trustworthy AI*. <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>

Facebook. (2021, July). *Captum: Model Interpretability for PyTorch*. <https://captum.ai/>

Ford, R. (2011, August). *Earthquake: Twitter Users Learned of Tremors Seconds Before Feeling Them*. <http://www.hollywoodreporter.com/news/earthquake-twitter-users-learned-tremors-226481>

Google. (2021, June). *People + AI Guidebook*. <https://pair.withgoogle.com/guidebook/>

Streamlit Inc. (2021, July). *Streamlit: The fastest way to build and share data apps*. <https://streamlit.io/>

ThinkSono. (2021, September). *The world's first software to detect DVT!* <https://thinksono.com/>

## Software

Apache Software Foundation. (2010, February 19). *Hadoop* (Version 0.20.2). <https://hadoop.apache.org>

Software-Name mit Versionsnummer und Link zur Website. Nur was für die konkrete Arbeit relevant ist. Das Sie die Arbeit mit Word geschrieben haben, ist irrelevant. Das sieht man. LaTeX auch.

# Abbreviations

**AI** Artificial Intelligence

**AII** Affinity for AI Interaction

**AUROC** Area Under the Receiver Operating Characteristics

**CNN** Convolutional Neural Network

**DNN** Deep Neural Network

**DVT** Deep Vein Thrombosis

**GUI** Graphical User Interface

**ML** Machine Learning

**XAI** Explainable Artificial Intelligence

# Glossary

**Artificial Intelligence** Systems that display intelligent behaviour by analyzing their environment and taking actions – with some degree of autonomy – to achieve specific goals.

**Affinity for AI Interaction** Tendency to actively engage in intensive AI interaction, as a key personal resource for coping with intelligent systems.

**Area Under the Receiver Operating Characteristics** Important evaluation metric for checking any classification model's performance.

**Black Box** System which can be viewed in terms of its inputs and outputs (or transfer characteristics), without any knowledge of its internal workings.

**Convolutional Neural Network** Convolutional neural networks are a class of artificial neural networks, most commonly used for processing structured arrays of data such as images..

**Deep Neural Network** Deep neural networks are a powerful category of machine learning algorithms implemented by stacking layers of neural networks along the depth and width of smaller architectures.

**Deep Vein Thrombosis** Deep vein thrombosis occurs when a blood clot forms in one or more of the deep veins in your body, usually in the legs.

**Explainable Artificial Intelligence** Artificial intelligence in which the results of the solution can be understood by humans.

**Machine Learning** Machine learning is a branch of artificial intelligence (AI) and computer science which focuses on the use of data and algorithms to imitate the way that humans learn, gradually improving its accuracy.

# Appendices

Zusätzliche Informationen die zu lang für die Arbeit sind können hier verfügbar gemacht werden.

Aber auch an die DVD denken — was ist dort besser aufgehoben? Die Zeiten, in denen man Programmcode manuell eingetippt hat, sind ja glücklicherweise lange vorbei, deswegen macht Code hier wenig Sinn.

Ist entsprechend ein Priorisierung: Was würde sich der Leser vielleicht gerne während des Lesens der Arbeit (z. B. im Zug) ansehen, wenn er auch gerade nicht auf die DVD zugreifen kann (kein DVD Laufwerk)?

Inhalte sind oft: Überblick der Inhalte der DVD, Fragebögen (falls digital Screenshots oder neu für den Druck formatiert), Interviewleitfäden, etc. Selten detailliertere Evaluationsergebnisse.

Hier kurz die Zwischenüberschriften nennen und evtl. 1 Satz, was dort zu finden ist (falls es nicht schon durch die Zwischenüberschrift klar ist).

Text ...

## Appendix A: Inhalt der DVD

Oft ein Default: Was findet man auf der beiliegenden DVD in welchem Verzeichnis? Max. 1 Seite.

**In jedem Fall** die PDF der Arbeit, den Programmcode, Daten (anonymisiert!).

**Niemals** Interviewaufzeichnungen, Einverständniserklärungen oder ähnliche personen-

bezogene Daten auf die DVD brennen — Sie haben in den meisten Fällen Anonymität zugesichert und die DVD ist frei zugänglich (ein Exemplar der Arbeit kommt in die Bibliothek).

Text ...

## **Appendix B: Interview Guideline**

Datum: \_\_\_\_\_  
ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



## Interviewleitfaden zur Nutzung, Vertrauenswürdigkeit und Erklärbarkeit von künstlicher Intelligenz

### Einführung

Begrüßung:

Hallo, vielen Dank, dass Sie sich Zeit genommen haben für dieses Interview. Ich bin **Philipp Bzdok** und studieren Medieninformatik im Master am Institut für Multimediale und Interaktive Systeme der Universität zu Lübeck. Unterstützt werde ich heute von **Mona Bickel**.

Erläuterung:

Wie Sie vielleicht schon wissen, möchte ich im Rahmen meiner Abschlussarbeit die Anforderungen und Bedürfnisse von Menschen für den professionellen Umgang mit KI-Systemen beleuchten. KI-Systeme sind in diesem Kontext Computer Systeme, welche durch den Einsatz von maschinellem Lernen komplexe Aufgaben lösen können (z.B. Erkennung von TVT in Ultraschall Bildern). Dies ist der erste wichtige Schritt für die Weiterentwicklung bestehender KI-Assessment-Systeme zur Förderung von Erklärbarkeit und Vertrauenswürdigkeit von KI in medizinischen Anwendungen. Denn nur wenn ein KI-System erklärbar und vertrauenswürdig ist, können auf Basis der Vorhersagen fundierte Entscheidungen im Arbeitsalltag getroffen werden.

Plan:

Heute möchte ich in diesem Interview herausfinden, was Ihre Erfahrungen, Bedürfnisse und Anforderungen bzgl. KI-Systemen im **wissenschaftlichen / medizinischen** (Arbeits-) Kontext sind. Hierbei geht es in erster Linie um Ihre subjektive Meinung und Erfahrung! Abschließend möchten ich noch ihre allgemeine Affinität zu KI Interaktion durch einen kurzen Fragebogen ermitteln.

Datenschutz und Einwilligung:

Wir würden das Interview für eine bessere Möglichkeit zur Auswertung gerne aufzeichnen. Die aufgezeichneten Daten werden anonymisiert für die Abschlussarbeit ausgewertet. Ist das für Sie in Ordnung?

**Start der Aufzeichnung**  
**Ziel: 2 Minuten pro Frage + Puffer**



Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



## Mediziner

### 1 Fragen zur Person

#### 1.1 Demografie

1.1.1 Alter \_\_\_\_\_

1.1.2 Geschlecht \_\_\_\_\_

1.1.3 Beruf \_\_\_\_\_

1.1.4 Bildungsstand \_\_\_\_\_

#### 1.2 Welche KI Systeme in Ihrem fachlichen Umfeld kennen Sie? (Frage zum Warmwerden)

---

---

---

---

#### 1.3 Welche KI-Systeme benutzen Sie im Arbeitsalltag? (Gebrauch von KI)

---

---

---

---

#### 1.3.1 Nachfrage, wenn Nutzung gegeben: Wie zufrieden waren Sie mit dem Gebrauch des KI-Systems? (Nachfrage zum Gebrauch)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.4 Welche **Vorteile** sehen Sie in Ihrem Arbeitsalltag beim Gebrauch von KI? (Perspektive zur KI Nutzung)

---

---

---

---

1.5 Welche **Risiken** sehen Sie in Ihrem Arbeitsalltag beim Gebrauch von KI? (Perspektive zur KI Nutzung)

---

---

---

---

Bitte denken Sie an einen konkreten Anwendungsfall von KI aus ihrem Arbeitsalltag und beschreiben Sie diesen kurz! (Alternativ: AutoDVT Use-Case etablieren) (Use-Case für weitere Fragen etablieren)

---

---

---

---

1.6 Inwiefern **vertrauen** Sie den Ergebnissen des KI-Systems (aus dem Use-Case)? (Vertrauen zu KI)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.6.1 Nachfrage: Aufgrund welcher **Informationen** bzw. Interaktion machen Sie dieses Vertrauen fest?

---

---

---

---

1.6.2 Nachfrage: Was waren Schlüsselmomente, die Ihr Vertrauen **verändert** haben?

---

---

---

---

1.7 Welche **Fragen** stellen Sie sich, wenn sie das System benutzen? (Potenzielle Probleme bei der KI Nutzung)

---

---

---

---

1.8 Wie gehen Sie vor, um die Funktionsweise des Systems zu **verstehen**? (Eigene Erklärungsmethoden)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.9 Was verstehen Sie unter dem Begriff „Erklärbare Künstliche Intelligenz“ oder auch „Explainable Artificial Intelligence“ (XAI)? (Vertrautheit mit XAI)

---

---

---

---

1.9.1 Nachfrage: Inwiefern könnte eine KI-Modell-Erklärung Ihr Vertrauen in die Vorhersagen des Systems verändern?

---

---

---

---

## 2 Fragen zur Interaktion mit KI-Assessment-Systemen

**Es ist ein System in der Entwicklung welches eine umfangreiche KI-Modell Bewertung erstellt. Eine solche Bewertung enthält Informationen über Veränderungen der Daten über die Zeit und besondere Randfälle. Des Weiteren zeigt es Modellgrenzen auf und bewertet die Robustheit und Interpretierbarkeit des Modells. Dazu werden diverse Erklärungsmethoden und Visualisierungen genutzt. (Einleitung des AI-Assessment Systems [Clearbox])**

2.1 Inwiefern könnten konkrete Beispiele (auch Local Explanations genannt) Ihnen helfen die Ergebnisse des KI-Modells besser zu **verstehen**? (Einschätzung zu Local Explanations)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



2.2 Wann würden konkrete Beispiele Ihnen **nicht** helfen die Ergebnisse des KI-Modells besser zu **verstehen**? (Einschätzung zu Local Explanations)

---

---

---

---

2.3 Wenn Sie das KI-System etwas Fragen könnten, um es besser **verstehen** zu können, was wäre es? (Primärfrage, Zeit lassen! Informationsverarbeitung)

---

---

---

---

2.4 Was würden Sie sich für die KI-Forschung **wünschen**, damit solche Systeme in Ihrem medizinischen Kontext mehr Anwendung finden können? (Vertrauen – Verhalten Verbindung)

---

---

---

---

2.5 Angenommen ein KI-System ist 100-prozentig zuverlässig, bräuchten Sie dann noch Erklärungen? (Zuverlässigkeit vs. Vertrauen vs. Verständnis)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



### 3 Abschluss

3.1 Haben Sie über die unsere Gesprächsinhalte noch weitere Anmerkungen oder Fragen?

---

---

---

---

4 AKII (ATI) Fragebogen per Limesurvey ausfüllen lassen.

(<https://bzdok.limesurvey.net/924128?lang=en>)

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



## **AI Researchers / Data Scientists**

### **1 Fragen zur Person**

#### 1 Demografie

1.1.1 Alter \_\_\_\_\_

1.1.2 Geschlecht \_\_\_\_\_

1.1.3 Beruf \_\_\_\_\_

1.1.4 Bildungsstand \_\_\_\_\_

#### 1.2 Welche Machine-Learning-Modelle nutzen Sie in Ihrem Arbeitsalltag? (Frage zum Warmwerden)

---

---

---

---

#### 1.3 Wie wählen Sie zwischen verschiedenen Machine-Learning-Modellen? (Gebrauch von KI)

---

---

---

---

#### 1.4 Was sind die wichtigsten Aspekte bei der Auswahl eines konkreten Modells? (Vergleich von KI-Modellen)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.5 Welche **Vorteile** sehen Sie beim Gebrauch von KI? (Perspektive zur KI-Nutzung)

---

---

---

---

1.6 Welche **Risiken** sehen Sie beim Gebrauch von KI? (Perspektive zur KI-Nutzung)

---

---

---

---

**Bitte denken Sie an einen konkreten Anwendungsfall von KI aus ihrem Arbeitsalltag und beschreiben Sie diesen kurz!** (Alternativ: AutoDVT Use-Case etablieren) (Use-Case für weitere Fragen etablieren)

---

---

---

---

1.7 Inwiefern **vertrauen** Sie den Ergebnissen des KI-Systems (aus dem Use-Case)?  
(Vertrauen zu KI)

---

---

---

---



Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.7.1 Nachfrage: Aufgrund welcher **Informationen** bzw. Interaktion machen Sie dieses Vertrauen fest?

---

---

---

---

1.7.2 Nachfrage: Was waren Schlüsselmomente, die Ihr Vertrauen **verändert** haben?

---

---

---

---

1.8 Welche **Fragen** stellen Sie sich, wenn sie das System benutzen? (Potenzielle Probleme bei der KI Nutzung)

---

---

---

---

1.9 Wie gehen Sie vor, um die Funktionsweise des Systems zu **verstehen**? (Eigene Erklärungsmethoden)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



1.10 Welche (XAI) Methoden zur Erklärbarkeit von KI haben Sie **bereits genutzt**?  
(Vertrautheit mit XAI)

---

---

---

---

1.10.1 Nachfrage für jede Methode: Inwiefern hat die XAI Methode ihr Vertrauen in die Vorhersagen des Modells **beeinflusst**?

---

---

---

---

## 2 Fragen zur Interaktion mit KI-Assessment-Systemen

Es ist ein System in der Entwicklung welches eine umfangreiche KI-Modell Bewertung erstellt. Eine solche Bewertung enthält Informationen über Veränderungen der Daten über die Zeit und besondere Randfälle. Des Weiteren zeigt es Modellgrenzen auf und bewertet die Robustheit und Interpretierbarkeit des Modells. Dazu werden diverse Erklärungsmethoden und Visualisierungen genutzt. (Einleitung des AI-Assessment Systems [Clearbox])

2.1 Wann brauchen Sie beispielhafte, **lokale Erklärungen** eines Machine-Learning-Modells? (Local Explanations Bedarf)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



2.2 Wann brauchen Sie **global valide Erklärungen** eines Machine-Learning-Modells?  
(Global Explanation Bedarf)

---

---

---

---

2.3 Wenn Sie das KI-System etwas Fragen könnten, um es besser **verstehen** zu können, was wäre es? (Primärfrage, Zeit lassen! Informationsverarbeitung)

---

---

---

---

2.4 Was würden Sie sich für die KI-Forschung **wünschen**, damit solche Systeme in Ihrem fachlichen Kontext mehr Anwendung finden können? (Vertrauen – Verhalten Verbindung)

---

---

---

---

2.5 Angenommen ein KI-System ist 100-prozentig zuverlässig, bräuchten Sie dann noch Erklärungen? (Zuverlässigkeit vs. Vertrauen vs. Verständnis)

---

---

---

---

Datum: \_\_\_\_\_

ID: \_\_\_\_\_



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR MULTIMEDIALE  
UND INTERAKTIVE SYSTEME



### **3 Abschluss**

3.1 Haben Sie über die unsere Gesprächsinhalte noch weitere Anmerkungen oder Fragen?

---

---

---

---

**4 AKII (ATI) Fragebogen per Limesurvey ausfüllen lassen.**

**(<https://bzdok.limesurvey.net/924128?lang=en>)**

## Appendix C: Interaction Flowcharts




Figure 7.1: Flowchart - Browse Training Data for a given Class




Figure 7.2: Flowchart - Show Examples of false positive / negative or low confidence




Figure 7.3: Flowchart - Show Similarities




Figure 7.4: Flowchart - Grouping of Data based on Similarities






Figure 7.5: Flowchart - Overview of General System Capabilities




Figure 7.6: Flowchart - Show Written Explanations via Templates




Figure 7.7: Flowchart - Input-Output Experiment

# Assertion under Oath

I declare in lieu of an oath that I have written this paper independently and have used only the sources indicated.

[Nach Ausdruck unterschreiben. Muss auf Papier sein.]

---

Lübeck, 1st December, 2021, Philipp Dominik Bzdok